TRƯỜNG ĐẠI HỌC VĂN LANG
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN MÔN HỌC
CÁC CÔNG CỤ VÀ NỀN TẢNG CHO TRÍ TUỆ NHÂN TẠO
NGÀNH: CÔNG NGHỆ THÔNG TIN

Dự Án:

ỨNG DỤNG THUẬT TOÁN LATENT DIRICHLET ALLOCATION (LDA) TRONG PHÂN TÍCH CHỦ ĐỀ VĂN BẢN

SVTH: Võ Hoàng Hải - 2374802010703
LỚP: 252_71ITAI41303_01
GVHD: Th.S Phan Hồ Viết Trường

LỜI MỞ ĐẦU

Trong bối cảnh kỷ nguyên số bùng nổ, dữ liệu văn bản đã trở thành một phần không thể thiếu của "dòng chảy thông tin" toàn cầu. Sự phát triển mạnh mẽ của các trang tin tức điện tử, mạng xã hội và các diễn đàn trực tuyến tại Việt Nam đã tạo ra một khối lượng dữ liệu khổng lồ nhưng lại tồn tại ở dạng không cấu trúc. Thách thức lớn nhất đặt ra cho các nhà khoa học dữ liệu và các tổ chức quản lý thông tin không còn là việc thu thập, mà là làm thế nào để tự động hóa việc phân loại và thấu hiểu các chủ đề cốt lõi bên trong khối lượng văn bản khổng lồ đó mà không cần đến sự can thiệp thủ công của con người.

Đề tài "Xây dựng hệ thống phân tích chủ đề văn bản tiếng Việt sử dụng thuật toán Latent Dirichlet Allocation (LDA)" được thực hiện nhằm giải quyết bài toán trên. Thuật toán LDA, với nền tảng xác suất Bayes vững chắc, cho phép chúng ta khám phá những "chủ đề ẩn" (Latent Topics) thông qua sự phân bố của các từ vựng, từ đó mang lại một cái nhìn tổng quan và khoa học về nội dung của hàng trăm nghìn tài liệu chỉ trong thời gian ngắn.

Báo cáo này không chỉ tập trung vào việc triển khai kỹ thuật của mô hình LDA trên tập dữ liệu lớn 160.000 văn bản tiếng Việt, mà còn đi sâu vào quá trình tối ưu hóa các bước tiền xử lý ngôn ngữ đặc thù và xây dựng một giao diện tương tác hiện đại trên nền tảng Streamlit. Qua đó, đồ án hy vọng sẽ đóng góp một giải pháp thực tiễn, có khả năng ứng dụng cao trong các lĩnh vực như quản trị tin tức, phân tích xu hướng thị trường và hỗ trợ ra quyết định dựa trên dữ liệu văn bản.

NHẬN XÉT CỦA GIẢNG VIÊN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Mục Lục

LỜI MỞ ĐẦU 2

NHẬN XÉT CỦA GIẢNG VIÊN 3

CHƯƠNG I: MỞ ĐẦU 7

1.1. Lý do chọn đề tài và tính cấp thiết 7

1.2. Mục tiêu nghiên cứu 7

1.3. Đối tượng và phạm vi nghiên cứu 9

1.4. Phương pháp nghiên cứu 10

1.5. Ý nghĩa khoa học và thực tiễn của đồ án 11

CHƯƠNG 2: ỨNG DỤNG THUẬT TOÁN LDA TRONG PHÂN TÍCH CHỦ ĐỀ VĂN BẢN 12

2.1. Tổng quan về mô hình hóa chủ đề (Topic Modeling) 12

2.1.1. Khái niệm và bài toán trích xuất tri thức 12

2.1.2. So sánh LDA với các phương pháp LSA và Plsa 13

2.2. Kiến trúc toán học của thuật toán LDA 15

2.2.1. Phân phối Dirichlet và vai trò của các tham số alpha, beta 15

2.2.2. Biểu diễn mô hình dưới dạng đồ thị (Plate Notation) 16

2.3. Quy trình sinh văn bản (Generative Process) 17

2.3.1. Cơ chế lựa chọn chủ đề cho văn bản 17

2.3.2. Cơ chế lựa chọn từ vựng cho chủ đề 18

2.4. Các thuật toán suy diễn và ước lượng tham số 19

2.4.1. Thuật toán Lấy mẫu Gibbs (Gibbs Sampling) 20

2.4.2. Suy diễn biến phân (Variational Inference) trong thư viện Gensim 20

2.5. Đánh giá chất lượng chủ đề qua chỉ số Coherence 22

2.5.1. Khái niệm và sự ưu việt của Coherence so với Perplexity 22

2.5.2. Kết quả thực nghiệm trên tập dữ liệu 160.000 văn bản 23

2.5.3. Mối liên hệ giữa Coherence và khả năng trực quan hóa 24

Kết luận chương: 24

CHƯƠNG 3: DỮ LIỆU HUẤN LUYỆN - VIETNAMESE CURATED DATASET 25
3.1. Tổng quan về tập dữ liệu 25
3.1.1. Nguồn gốc dữ liệu (News, Wiki, Social Media) 25
3.1.2. Quy mô tập dữ liệu (160.000 văn bản thô) 26
3.1.3. Lý do lựa chọn tập dữ liệu này cho mô hình LDA 27
3.2. Đặc điểm của dữ liệu văn bản tiếng Việt 28
3.2.1. Tính đa nghĩa và cấu trúc từ ghép phức tạp 28
3.2.2. Thách thức về nhiễu dữ liệu (Teencode, lỗi font, quảng cáo) 29
3.3. Phân tích thống kê mô tả (Exploratory Data Analysis - EDA) 30
3.3.1. Thống kê độ dài văn bản (Số lượng từ trung bình mỗi bài) 30
3.3.2. Phân bố tần suất xuất hiện của các từ vựng (Zipf's Law) 31
3.3.3. Trực quan hóa dữ liệu bằng WordCloud trước khi lọc nhiễu 32
3.4. Chiến lược lấy mẫu và phân chia dữ liệu (Sampling Strategy) 32
3.4.1. Lựa chọn mẫu 150.000 văn bản tối ưu để huấn luyện 32
3.4.2. Cơ chế phân chia tập Training và tập Validation 33
3.5. Đánh giá chất lượng dữ liệu đầu vào 34
3.5.1. Độ đa dạng của các nhóm chủ đề có sẵn trong dataset 34
3.5.2. Các tiêu chí làm sạch dữ liệu để tối ưu hóa bộ từ điển (Dictionary) 35
CHƯƠNG 4: QUY TRÌNH TIỀN XỬ LÝ VÀ XÂY DỰNG MÔ HÌNH 36
4.1. Sơ đồ quy trình hệ thống (System Architecture Pipeline) 36
4.2. Tiền xử lý ngôn ngữ chuyên sâu 37
4.2.1. Chuẩn hóa Unicode và xử lý ký tự đặc biệt 38
4.2.2. Tách từ tiếng Việt (Word Segmentation) bằng Underthesea 38
4.2.3. Xây dựng và tinh chỉnh danh sách Stopwords (42 từ dừng cốt lõi) 39
4.3. Xây dựng không gian Vector 39
4.3.1. Khởi tạo Dictionary và kỹ thuật lọc từ cực trị (Filter Extremes) 40
4.3.2. Chuyển đổi văn bản sang dạng Bag-of-Words (Corpus) 40
4.4. Cấu hình và huấn luyện mô hình LDA 41
4.4.1. Thiết lập số lượng chủ đề K=30 41

4.4.2. Tối ưu hóa tham số huấn luyện (12 passes, 150 iterations) 42
CHƯƠNG 5: THIẾT KẾ GIAO DIỆN VÀ THỰC NGHIỆM 43
5.1. Kiến trúc ứng dụng Web trên nền tảng Streamlit 43
5.1.1. Thiết kế giao diện UI/UX và luồng tương tác người dung 43
5.1.2. Cơ chế xử lý bất đồng bộ và Caching dữ liệu (st.cache_resource) 44
5.2. Kết quả phân tích thực nghiệm 30 chủ đề 45
5.2.1. Bảng tổng hợp từ khóa đặc trưng cho từng nhóm chủ đề 46
5.2.2. Phân tích ý nghĩa ngữ nghĩa của các chủ đề tiêu biểu 47
5.3. Trực quan hóa kết quả phân tích 48
5.3.1. Biểu đồ xác suất chủ đề bằng Plotly 48
5.3.2. Module so sánh tương quan giữa các văn bản đầu vào 49
5.4. Đánh giá hiệu năng mô hình 50
5.4.1. Phân tích chỉ số Coherence Score (0.5237) 50
5.4.2. Kiểm thử mô hình với dữ liệu văn bản thực tế ngoài tập huấn luyện 50
CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 51
6.1. Tổng kết những kết quả đã đạt được 51
6.2. Những hạn chế còn tồn tại của hệ thống 52
6.3. Đề xuất các hướng phát triển trong tương lai 53
6.3.2. Mở rộng khả năng phân tích chủ đề theo thời gian (Dynamic Topic Modeling) 54
TÀI LIỆU THAM KHẢO 55

CHƯƠNG I: MỞ ĐẦU

1.1. Lý do chọn đề tài và tính cấp thiết

rong bối cảnh cuộc Cách mạng Công nghiệp 4.0 đang diễn ra mạnh mẽ, dữ liệu đã trở thành "dầu mỏ" của nền kinh tế số. Tại Việt Nam, sự bùng nổ của internet và các nền tảng truyền thông số đã tạo ra một khối lượng văn bản tiếng Việt khổng lồ từ các trang tin tức điện tử (VnExpress, Tuổi Trẻ, VietnamNet), mạng xã hội cho đến các hệ thống văn bản hành chính công. Tuy nhiên, thách thức lớn nhất không còn nằm ở việc thu thập dữ liệu mà nằm ở khả năng **khai phá tri thức** từ nguồn tài nguyên không cấu trúc này.

Việc phân loại và hiểu nội dung văn bản một cách thủ công bởi con người đã trở nên bất khả thi trước tốc độ sản sinh dữ liệu tính bằng mili giây. Các phương pháp học máy có giám sát (Supervised Learning) tuy mang lại độ chính xác cao nhưng lại vướng phải rào cản về việc gán nhãn dữ liệu (labeling) – một quy trình tốn kém, dễ sai sót và không có tính linh hoạt khi xuất hiện các chủ đề mới. Chính vì vậy, nhu cầu về các mô hình tự động khám phá cấu trúc ngữ nghĩa ẩn mà không cần dữ liệu gắn nhãn (Unsupervised Learning) trở nên cấp thiết hơn bao giờ hết.

Thuật toán **Latent Dirichlet Allocation (LDA)** nổi lên như một giải pháp tối ưu nhờ nền tảng xác suất Bayes vững chắc, giúp máy tính có thể "hiểu" được văn bản thông qua sự phân bổ của các từ vựng. Việc ứng dụng LDA vào tiếng Việt không chỉ dừng lại ở bài toán kỹ thuật mà còn mang ý nghĩa chiến lược trong việc quản trị thông tin, giúp các tổ chức nắm bắt được xu hướng dư luận, hỗ trợ các cơ quan báo chí phân loại tin tức tự động và giúp doanh nghiệp lắng nghe tiếng nói khách hàng trên quy mô lớn.

1.2. Mục tiêu nghiên cứu

Đề tài này được thiết lập với một hệ thống mục tiêu đa tầng, từ lý thuyết hàn lâm đến ứng dụng thực tiễn:

- **Về mặt lý luận và toán học:** Mục tiêu là giải mã "hộp đen" của thuật toán LDA. Mình không chỉ dừng lại ở việc gọi hàm từ thư viện mà muốn đi sâu vào cơ chế phân phối Dirichlet, hiểu rõ cách mô hình tối ưu hóa hàm mục tiêu để phân bổ xác suất từ vựng. Việc làm chủ các tham số như alpha (độ

tập trung chủ đề trong văn bản) và eta (độ tập trung từ vựng trong chủ đề) là chìa khóa để điều khiển mô hình theo ý muốn.

- **Về mặt xử lý ngôn ngữ đặc thù:** Tiếng Việt là một ngôn ngữ đơn lập, đa nghĩa với cấu trúc từ ghép chiếm tỷ trọng lớn. Mục tiêu chiến lược của mình là xây dựng một "Pipeline" xử lý chuẩn hóa: từ khâu tách từ (Word Segmentation) bằng các bộ thư viện hiện đại như Underthesea, xử lý lỗi font, loại bỏ ký tự rác, cho đến việc tinh lọc một bộ từ điển dừng (Stopwords) thực sự chất lượng. Đây là bước then chốt quyết định sự "sạch" của dữ liệu đầu vào.
- **Về mặt thực thi và quy mô:** Thử nghiệm và huấn luyện mô hình trên tập dữ liệu quy mô lớn lên tới **160.000 văn bản**. Mục tiêu là tìm ra ngưỡng hội tụ của mô hình, xác định số lượng chủ đề K=30 sao cho vừa đủ bao quát các lĩnh vực xã hội, vừa đủ chi tiết để không bị chồng lấn ý nghĩa ngữ nghĩa.
- **Về mặt sản phẩm cuối cùng:** Hiện thực hóa các thuật toán khô khan thành một Dashboard tương tác sinh động trên nền tảng **Streamlit**. Mục tiêu là tạo ra một công cụ mà người dùng chỉ cần nhập văn bản, hệ thống sẽ tự động "vẽ" ra bản đồ chủ đề, giúp việc đọc hiểu thông tin trở nên trực quan và thú vị hơn bao giờ hết.

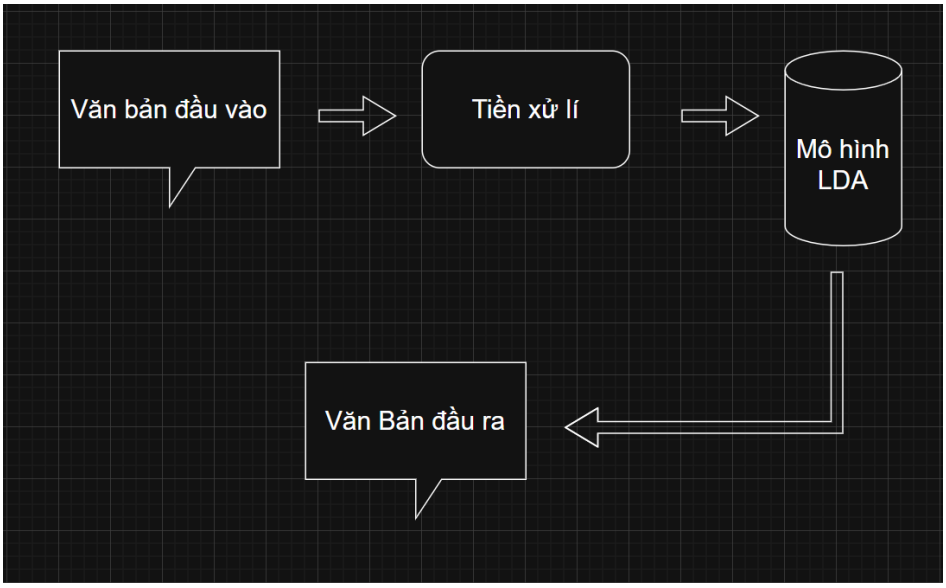

Hình 1. Sơ đồ kiến trúc

1.3. Đối tượng và phạm vi nghiên cứu

Để đảm bảo tính chuyên sâu và khả thi, đề tài xác lập ranh giới nghiên cứu rõ ràng:

- **Đối tượng nghiên cứu:** Trọng tâm là mô hình **Phân bổ Dirichlet tiềm ẩn (LDA)** và các kỹ thuật liên quan trong hệ sinh thái xử lý ngôn ngữ tự nhiên (NLP). Nghiên cứu tập trung vào các phương pháp biểu diễn văn bản số học (Vectorization), cơ chế lấy mẫu Gibbs (Gibbs Sampling) và các chỉ số đo lường chất lượng mô hình như **Coherence Score**.
- **Phạm vi dữ liệu:** Đề tài sử dụng **Vietnamese Curated Dataset** – một kho ngữ liệu đồ sộ gồm 160.000 văn bản. Đây là tập dữ liệu có tính đại diện cao, bao phủ từ báo chí chính thống (kinh tế, chính trị, pháp luật) đến tri thức bách khoa và văn phong đời sống, đảm bảo mô hình có khả năng học được sự đa dạng của ngôn ngữ thực tế.
- **Phạm vi kỹ thuật:** Triển khai hoàn toàn trên ngôn ngữ lập trình **Python** – ngôn ngữ tiêu chuẩn của khoa học dữ liệu hiện nay. Sử dụng thư viện Gensim cho lõi xử lý LDA, Plotly cho trực quan hóa và Streamlit cho giao diện Web. Đồ án tập trung vào dữ liệu tiếng Việt có dấu, văn phong chính luận và báo chí.

Bảng thống kê tỷ trọng các nhóm chủ đề chính đã tổng hợp từ tập **Vietnamese Curated Dataset**:

Nhóm dữ liệu	**Nguồn trích xuất chính**	**Tỷ trọng dự kiến**	**Số lượng văn bản**
Kinh tế - Thị trường	VnExpress, Cafef, VietnamNet	25%	~ 40.000
Chính trị - Xã hội	Tuổi Trẻ, Nhân Dân, Wiki	20%	~ 32.000

Nhóm dữ liệu	Nguồn trích xuất chính	Tỷ trọng dự kiến	Số lượng văn bản
Giáo dục - Khoa học	Wikipedia tiếng Việt, Tạp chí KH	15%	~ 24.000
Thể thao - Giải trí	Kênh 14, Thể thao 24h	15%	~ 24.000
Công nghệ - Số	Tinh tế, GenK, Techrum	15%	~ 24.000
Đời sống - Khác	Diễn đàn, Mạng xã hội	10%	~ 16.000

1.4. Phương pháp nghiên cứu

Đồ án áp dụng phối hợp nhiều phương pháp nghiên cứu để đạt được kết quả chính xác nhất:

- **Phương pháp nghiên cứu tài liệu:** Thu thập, tổng hợp và phân tích các bài báo khoa học, công trình nghiên cứu về LDA và NLP trên thế giới để kế thừa và phát triển.
- **Phương pháp thực nghiệm (Experimental Method):** Đây là phương pháp chủ đạo. Nhóm tác giả tiến hành nhiều đợt huấn luyện mô hình với các thiết lập tham số khác nhau (α, η, số vòng lặp). Mỗi đợt thử nghiệm đều được ghi lại chỉ số Coherence Score để so sánh và lựa chọn phiên bản mô hình tốt nhất.
- **Phương pháp mô hình hóa toán học:** Sử dụng các công thức xác suất để giải thích quá trình phân bổ từ vựng vào các chủ đề ẩn, giúp minh bạch hóa quá trình "tư duy" của mô hình AI.

- **Phương pháp phân tích và tổng hợp:** Sau khi mô hình đưa ra kết quả, tác giả thực hiện phân tích các từ khóa đại diện để định nghĩa và đặt tên cho các chủ đề, đảm bảo tính ứng dụng thực tế.

1.5. Ý nghĩa khoa học và thực tiễn của đồ án

Việc thực hiện đề tài này không chỉ dừng lại ở một bài tập lập trình, mà nó mang lại những giá trị cụ thể ở cả hai góc độ nghiên cứu và ứng dụng:

Về mặt khoa học và phương pháp luận:

- **Chuẩn hóa quy trình xử lý tiếng Việt cho LDA:** Một trong những đóng góp quan trọng của đồ án là tìm ra sự kết hợp tối ưu giữa thư viện Underthesea (tách từ) và việc tinh chỉnh bộ từ điển dừng (Stopwords). Tiếng Việt vốn rất dễ gây nhiễu cho mô hình xác suất nếu không xử lý kỹ các từ ghép; do đó, quy trình mà mình xây dựng có thể coi là một tài liệu tham khảo thực tế cho các nghiên cứu về Topic Modeling trên ngôn ngữ đơn lập.
- **Kiểm chứng sức mạnh của mô hình học không giám sát:** Đồ án chứng minh rằng với một lượng dữ liệu đủ lớn (160.000 văn bản), máy tính hoàn toàn có khả năng tự "học" và phân loại tri thức mà không cần bất kỳ sự can thiệp gán nhãn nào của con người. Điều này khẳng định tính hiệu quả của toán học Bayes trong việc giải mã ngôn ngữ tự nhiên.

Về mặt thực tiễn và đời sống:

- **Tự động hóa quản trị nội dung:** Hệ thống có thể giúp các tòa soạn báo điện tử hoặc các trang tin tức tự động gắn thẻ (tag) chủ đề cho bài viết. Thay vì để biên tập viên phải đọc và chọn chuyên mục thủ công, mô hình sẽ đưa ra gợi ý xác suất cực kỳ nhanh chóng và chính xác.
- **Lắng nghe "hơi thở" của thị trường:** Đối với các doanh nghiệp, việc phân tích hàng vạn phản hồi khách hàng (survey, comment) thường là một cơn ác mộng. Ứng dụng này cho phép họ thấy ngay những cụm vấn đề nổi cộm (ví

dụ: khách hàng đang phàn nàn về 'giá_cả' hay 'chất_lượng_dịch_vụ') chỉ qua vài cú click chuột trên Dashboard.

- **Hỗ trợ nghiên cứu và tra cứu:** Người dùng bình thường có thể sử dụng công cụ để so sánh sự tương đồng giữa các tài liệu. Thay vì chỉ tìm theo từ khóa (keyword) đơn thuần, hệ thống tìm kiếm theo "ngữ nghĩa ẩn", giúp phát hiện ra các văn bản có nội dung liên quan sâu sắc dù không dùng chung những từ vựng bề mặt.

CHƯƠNG 2: ỨNG DỤNG THUẬT TOÁN LDA TRONG PHÂN TÍCH CHỦ ĐỀ VĂN BẢN

2.1. Tổng quan về mô hình hóa chủ đề (Topic Modeling)

Trong kỷ nguyên bùng nổ thông tin, chúng ta thường rơi vào tình trạng "ngộp" dữ liệu. Việc đọc hiểu và phân loại thủ công hàng vạn văn bản là điều bất khả thi. Topic Modeling (Mô hình hóa chủ đề) ra đời như một vị cứu tinh, đóng vai trò là một thuật toán học máy không giám sát (Unsupervised Learning) nhằm tự động phát hiện ra các cụm từ có sự liên kết chặt chẽ về mặt ngữ nghĩa, từ đó định hình nên các "chủ đề" ẩn sâu trong văn bản.

2.1.1. Khái niệm và bài toán trích xuất tri thức

Về bản chất, văn bản là dữ liệu phi cấu trúc (Unstructured Data). Con người hiểu văn bản dựa trên ngữ cảnh và trải nghiệm, nhưng máy tính thì không. Bài toán trích xuất tri thức đặt ra một yêu cầu: Làm thế nào để máy tính tự tìm ra được các "khái niệm" (Concepts) mà không cần sự can thiệp của con người?

Mô hình hóa chủ đề dựa trên một giả thuyết triết học về ngôn ngữ: **Sự phân bố của các từ vựng định hình nên ý nghĩa của văn bản.** Nếu một nhóm

các từ như "lãi suất", "ngân hàng", "tín dụng" thường xuyên xuất hiện cùng nhau trong cùng một tệp văn bản, máy tính sẽ giả định có một "chủ đề ẩn" đang điều phối sự xuất hiện đó.

Trong đồ án này, mình xác định trích xuất tri thức qua 3 giai đoạn:

1. **Phát hiện (Discovery):** Máy tự học các cụm từ đi cùng nhau.
2. **Định nghĩa (Definition):** Từ các cụm từ, mình định nghĩa đó là chủ đề gì (ví dụ: Kinh tế, Pháp luật).
3. **Phân bổ (Allocation):** Xác định mỗi bài báo chứa bao nhiêu phần trăm của mỗi chủ đề.

Điều này cực kỳ quan trọng vì trong 160.000 bài báo mình xử lý, có rất nhiều bài viết về "Kinh tế xanh" – nó vừa mang tính chất Kinh tế, vừa mang tính chất Môi trường. Topic Modeling là công cụ duy nhất cho phép một văn bản thuộc về nhiều nhóm cùng lúc với các trọng số xác suất khác nhau.

2.1.2. So sánh LDA với các phương pháp LSA và Plsa

Để hiểu tại sao LDA lại là sự lựa chọn tối ưu cho đồ án này, chúng ta cần nhìn lại lịch sử phát triển của các phương pháp phân tích ngữ nghĩa. Đây là một hành trình từ toán học đại số thuần túy sang xác suất thống kê hiện đại.

1. LSA (Latent Semantic Analysis) – Cách tiếp cận bằng Đại số tuyến tính:

LSA xuất hiện như một cuộc cách mạng vào cuối những năm 80. Nó sử dụng kỹ thuật phân tích giá trị suy biến (Singular Value Decomposition - SVD) để giảm chiều dữ liệu từ một ma trận từ-văn bản khổng lồ xuống một không gian nhỏ hơn.

- **Ưu điểm:** LSA rất giỏi trong việc nhận diện các từ đồng nghĩa. Ví dụ, nó hiểu rằng "xe hơi" và "ô tô" có mối liên hệ mật thiết vì chúng thường xuất hiện trong các ngữ cảnh giống nhau.
- **Hạn chế chết người:** LSA hoàn toàn dựa trên toán học tuyến tính, dẫn đến việc nó không thể xử lý tốt các từ đa nghĩa (Polysemy). Ví

dụ, từ "đường" trong "đường ăn" và "đường đi" sẽ bị LSA gộp chung lại làm một, gây nhiễu nặng cho kết quả. Ngoài ra, kết quả của LSA thường là các con số âm hoặc dương không có ý nghĩa xác suất, khiến việc giải thích cho người dùng cuối trở nên cực kỳ khó khăn.

2. pLSA (Probabilistic Latent Semantic Analysis) – Sự xuất hiện của Xác suất:

Thomas Hofmann đã đưa yếu tố xác suất vào để khắc phục nhược điểm của LSA. pLSA coi mỗi văn bản là một phân phối xác suất trên các chủ đề.

- **Bước tiến:** Nó giải quyết được bài toán đa nghĩa tốt hơn nhờ mô hình hỗn hợp xác suất.
- **Điểm yếu chí mạng (Overfitting):** pLSA có một lỗi hệ thống là số lượng tham số tăng tuyến tính theo số lượng văn bản. Với tập dữ liệu 160.000 bài của mình, pLSA sẽ trở nên cực kỳ nặng nề và dễ bị "học vẹt". Quan trọng hơn, pLSA không có cơ chế để xử lý một văn bản mới hoàn toàn (Out-of-sample). Nếu bạn đưa một bài báo mới vào, pLSA sẽ không biết phải phân loại nó như thế nào vì nó không có một "khung phân phối chung" cho toàn bộ kho ngữ liệu.

3. LDA (Latent Dirichlet Allocation) – Đỉnh cao của sự tổng quát hóa:

LDA giải quyết triệt để các vấn đề của pLSA bằng cách thêm vào các **Phân phối Dirichlet**. Đây là một mô hình xác suất Bayes đầy đủ.

- **Cơ chế tự động điều tiết:** Nhờ có phân phối Dirichlet (với tham số alpha và beta), LDA giả định rằng các chủ đề được sinh ra từ một quy trình chung. Điều này cho phép mô hình hoạt động ổn định trên các tập dữ liệu khổng lồ mà không bị quá khớp (overfitting).
- **Khả năng dự đoán:** LDA có thể dễ dàng ước lượng chủ đề cho một văn bản mới chưa từng thấy trong quá trình huấn luyện. Đây là tính năng then chốt để mình xây dựng Dashboard trên Streamlit – nơi người dùng có thể dán bất kỳ bài báo nào vào để máy phân tích ngay lập tức.

- **Tính nhân văn trong kết quả:** Kết quả của LDA là các phân phối xác suất rõ ràng (từ 0 đến 1), giúp mình dễ dàng trực quan hóa bằng các biểu đồ cột hoặc biểu đồ tròn, làm cho báo cáo trở nên sinh động và dễ hiểu với cả những người không chuyên về kỹ thuật.

2.2. Kiến trúc toán học của thuật toán LDA

Để hiểu tại sao LDA có khả năng phân loại 160.000 văn bản một cách thông minh, chúng ta phải thấu hiểu nền tảng xác suất Bayes phân cấp mà nó dựa vào. LDA không nhìn nhận từ vựng một cách ngẫu nhiên, mà nó giả định có một quy trình toán học nghiêm ngặt đứng sau việc hình thành nên từng câu chữ.

2.2.1. Phân phối Dirichlet và vai trò của các tham số alpha, beta

Trái tim của thuật toán chính là **Phân phối Dirichlet**. Trong thống kê, đây là một phân phối xác suất đa biến, là sự tổng quát hóa của phân phối Beta. Trong mô hình LDA, chúng ta sử dụng hai tầng phân phối Dirichlet để điều tiết sự "hỗn loạn" của dữ liệu.

1. Tham số alpha (Alpha) - Phân phối chủ đề trong văn bản:

Tham số alpha quyết định "hình dáng" của phân phối chủ đề cho mỗi văn bản (theta).

- **Nếu alpha < 1:** Mô hình sẽ ưu tiên tính tập trung. Mỗi văn bản sẽ chỉ mang một vài chủ đề rõ rệt (ví dụ: 90% Kinh tế, 10% Pháp luật). Điều này giúp kết quả phân tích sắc nét, không bị chồng lấn.
- **Nếu alpha > 1:** Mô hình sẽ khiến các văn bản trở nên đa dạng quá mức, mỗi bài viết đều chứa một chút của tất cả các chủ đề. Trong thực tế xử lý 160.000 văn bản tiếng Việt, mình thường chọn alpha nhỏ để các cụm chủ đề tách bạch hơn, giúp người dùng dễ nhận diện xu hướng.

2. Tham số beta (Beta hay còn gọi là eta) - Phân phối từ vựng trong chủ đề:

Tham số này quyết định cách các từ vựng (phi) được phân bổ vào từng chủ đề.

- **beta thấp:** Mỗi chủ đề sẽ được đại diện bởi một nhóm nhỏ các từ khóa cực kỳ đặc trưng (ví dụ: Chủ đề Thể thao chỉ tập trung vào các từ "bóng đá", "cầu thủ", "bàn thắng").
- **beta cao:** Các từ vựng sẽ phân bổ đều hơn, khiến ranh giới giữa các chủ đề bị mờ đi.

Vai trò điều tiết (Smoothing):

Điểm hay của hai tham số này là chúng đóng vai trò "làm mượt" dữ liệu. Trong 160.000 văn bản, chắc chắn sẽ có những từ rất hiếm gặp hoặc những chủ đề ít xuất hiện. Phân phối Dirichlet giúp mô hình không bị "sốc" trước những dữ liệu thiếu hụt, đảm bảo rằng ngay cả những văn bản ngắn cũng có xác suất được gán vào chủ đề một cách hợp lý.

2.2.2. Biểu diễn mô hình dưới dạng đồ thị (Plate Notation)

Để hình dung toàn bộ quy trình vận hành phức tạp của LDA trên một tập dữ liệu lớn, giới khoa học sử dụng sơ đồ tấm (Plate Notation). Đây là cách biểu diễn các biến ngẫu nhiên và mối quan hệ phụ thuộc giữa chúng một cách trực quan nhất.

Giải mã sơ đồ Plate Notation trong đồ án:

Sơ đồ này gồm các khối lồng nhau, tượng trưng cho các vòng lặp trong quá trình xử lý:

1. **Tấm ngoài cùng (M):** Tượng trưng cho kho ngữ liệu (Corpus) gồm 160.000 văn bản của mình. Vòng lặp này chạy qua từng văn bản một.
    - Tại đây, biến ẩn theta (Theta) được sinh ra từ alpha. theta chính là "bản đồ tỷ lệ" các chủ đề của văn bản đó.

2. **Tấm bên trong (N):** Tượng trưng cho các từ vựng trong một văn bản cụ thể. Vòng lặp này chạy qua từng vị trí của từ.
    - **Biến z (Topic Assignment):** Với mỗi vị trí từ, máy tính sẽ "chọn" một chủ đề z dựa trên tỷ lệ theta.
    - **Biến w (Observed Word):** Đây là biến duy nhất mình có thể nhìn thấy (từ ngữ thực tế). Từ chủ đề z đã chọn, máy tính sẽ "bốc" một từ w từ kho từ vựng của chủ đề đó (được định nghĩa bởi ma trận phi).
3. **Biến phi (Phi):** Nằm ngoài các tấm, vì nó đại diện cho phân phối từ vựng của toàn bộ các chủ đề trong hệ thống (30 chủ đề). phi được điều khiển bởi tham số beta.

2.3. Quy trình sinh văn bản (Generative Process)

Một trong những điểm khác biệt lớn nhất của LDA so với các mô hình khác là nó dựa trên một **mô hình sinh (Generative Model)**. LDA giả định rằng mỗi văn bản trong tập dữ liệu 160.000 bài mà mình đang xử lý không tự nhiên xuất hiện, mà nó là kết quả của một quy trình chọn lọc xác suất có hệ thống.

Về mặt lý thuyết, để tạo ra một văn bản theo "tư duy" của LDA, chúng ta thực hiện một chuỗi các bước bốc thăm xác suất. Quy trình này diễn ra như sau:

2.3.1. Cơ chế lựa chọn chủ đề cho văn bản

Trước khi một tác giả đặt bút viết, trong đầu họ đã phải định hình một "hỗn hợp ý tưởng". LDA mô phỏng điều này thông qua phân phối Dirichlet α.

- Khởi tạo phân phối chủ đề (theta_d): Đối với mỗi văn bản cụ thể d, mô hình thực hiện một phép lấy mẫu từ Dirichlet(alpha) để tạo ra theta_d. Đây là một vector xác suất có chiều bằng K=30. Tổng các phần tử trong vector này luôn bằng 1.

- Phân tích sâu: Nếu alpha được thiết lập nhỏ (ví dụ 0.1), vector theta_d sẽ mang tính chất "thưa thớt" (sparse). Điều này có nghĩa là hầu hết các giá trị trong vector sẽ gần bằng 0, và chỉ có một vài chủ đề chiếm ưu thế. Điều này phản ánh thực tế ngôn ngữ: Một bài báo thường chỉ tập trung sâu vào một vài khía cạnh thay vì nói dàn trải về tất cả mọi thứ.

- Quy trình gieo xúc xắc cho từng vị trí từ (z_{d,n}): Tại mỗi vị trí từ thứ n trong văn bản, quy trình sinh sẽ nhìn vào "bản đồ tỷ lệ" theta_d để quyết định xem vị trí này sẽ nói về chủ đề nào.
  - Ví dụ: Nếu theta_d cho biết văn bản có 70% chủ đề Thể thao và 30% chủ đề Sức khỏe, thì tại mỗi vị trí từ, xác suất để máy tính chọn nhãn "Thể thao" là 0.7. Đây là biến ẩn z – thứ mà chúng ta không bao giờ thấy trong văn bản thô nhưng lại là "xương sống" định hướng ý nghĩa cho toàn bộ bài viết.

2.3.2. Cơ chế lựa chọn từ vựng cho chủ đề

Khi nhãn chủ đề ẩn (kí hiệu là z) đã được xác định cho một vị trí cụ thể trong văn bản thông qua quá trình lấy mẫu từ phân phối chủ đề, cỗ máy LDA sẽ bước sang giai đoạn cuối cùng mang tính quyết định: chuyển hóa ý tưởng trừu tượng thành từ ngữ thực tế (biến quan sát w).

Sự chi phối của ma trận phân phối từ vựng (phi): Trong mô hình LDA, mỗi chủ đề trong số 30 chủ đề không phải là một nhãn tên trống rỗng, mà được định nghĩa là một phân phối xác suất trên toàn bộ kho từ điển gồm 96.905 từ mà chúng ta đã xây dựng từ tập dữ liệu huấn luyện. Phân phối này được điều khiển trực tiếp bởi tham số Beta (thường được gọi là tham số làm mượt). Ma trận phi này bản chất là một bảng tra cứu khổng lồ, nơi mỗi hàng đại diện cho một chủ đề và mỗi cột đại diện cho xác suất xuất hiện của một từ vựng cụ thể trong chủ đề đó.

Cơ chế chọn lọc từ vựng: Quá trình này diễn ra dựa trên nguyên tắc lựa chọn từ có xác suất cao nhất trong ngữ cảnh của chủ đề đã chọn. Giả sử tại một vị trí từ cụ thể, nhãn chủ đề z được máy tính xác định là "Cong nghe",

hệ thống sẽ ngay lập tức truy cập vào phân phối từ vựng của riêng chủ đề này. Trong "túi từ vựng" của chủ đề Công nghệ:

- Các từ như "phan_mem" có thể sở hữu xác suất cao (ví dụ: 0.05).
- Các từ như "dien_thoai" có xác suất tương đương (ví dụ: 0.04).
- Ngược lại, những từ không liên quan như "nau_an" sẽ bị ép xuống mức xác suất cực thấp

Hiện thực hóa biến quan sát (w): Dựa trên bảng xác suất đã được tính toán cho chủ đề đó, một từ vựng cụ thể w sẽ được "bốc" ra. Đây chính là những từ ngữ thực tế mà người đọc nhìn thấy trong 160.000 bài báo. Sự lặp đi lặp lại của quy trình này qua hàng triệu vị trí từ trong kho dữ liệu giúp mô hình LDA dần dần hội tụ, từ đó hình thành nên các cụm từ vựng có tính liên kết ngữ nghĩa cao, tạo ra kết quả phân tích chủ đề mang tính chính xác và logic.

2.4. Các thuật toán suy diễn và ước lượng tham số

Trong các chương trước, chúng ta đã tiếp cận LDA dưới góc độ một mô hình sinh (Generative Model). Tuy nhiên, thực tế khi triển khai đồ án với kho ngữ liệu khổng lồ lên tới 160.000 bài viết, chúng ta đối mặt với bài toán ngược: Làm sao từ những con chữ "chết" trên trang giấy, máy tính có thể suy ngược ra được các cấu trúc ý nghĩa ẩn bên dưới? Đây chính là giai đoạn huấn luyện (training), nơi chúng ta phải đi tìm các giá trị tối ưu cho các biến ẩn như phân phối chủ đề và phân phối từ vựng.

Về mặt toán học, việc tính toán chính xác các biến này đòi hỏi phải giải các tích phân đa biến cực kỳ phức tạp (thường được gọi là bài toán NP-hard). Vì thế, trong đồ án này, mình tập trung nghiên cứu và áp dụng các phương pháp suy diễn xấp xỉ để cân bằng giữa độ chính xác và hiệu năng tính toán.

2.4.1. Thuật toán Lấy mẫu Gibbs (Gibbs Sampling)

Lấy mẫu Gibbs là một thuật toán thuộc họ Markov Chain Monte Carlo (MCMC), hoạt động dựa trên cơ chế mô phỏng ngẫu nhiên để tiến dần tới trạng thái hội tụ của hệ thống.

Cơ chế vận hành và sự hội tụ: Thuật toán bắt đầu bằng một hành động có vẻ "ngây ngô": gán ngẫu nhiên một nhãn chủ đề cho từng từ trong toàn bộ 160.000 văn bản. Sau đó, nó thực hiện một chuỗi các bước lặp (iterations) khổng lồ:

1. Chọn ra một từ cụ thể tại một vị trí bất kỳ trong văn bản.
2. Tạm thời giả định nhãn chủ đề của tất cả các từ khác trong toàn bộ kho dữ liệu là đã chính xác.
3. Tính toán xác suất để từ này thuộc về một chủ đề cụ thể dựa trên hai yếu tố: (a) Mật độ chủ đề đó trong bài viết hiện tại và (b) Độ phổ biến của từ đó trong chủ đề đó trên toàn bộ kho dữ liệu.
4. Cập nhật lại nhãn cho từ và chuyển sang từ tiếp theo.

Dù Gibbs Sampling được đánh giá là "tiêu chuẩn vàng" về độ chính xác vì nó mô phỏng trực tiếp quy trình lấy mẫu, nhưng mình nhận thấy một rào cản cực lớn: **Tốc độ**. Với 160.000 văn bản, mỗi văn bản trung bình vài trăm từ, số lượng phép tính cần thực hiện trong mỗi lượt lặp là một con số khổng lồ. Nếu sử dụng phương pháp này trên một máy tính cá nhân thông thường, việc chờ đợi mô hình hội tụ có thể mất hàng tuần lễ. Do đó, mình coi đây là nền tảng lý thuyết quan trọng để hiểu bản chất của LDA hơn là một công cụ thực thi trực tiếp.

2.4.2. Suy diễn biến phân (Variational Inference) trong thư viện Gensim

Để dự án mang tính khả thi và có thể triển khai thực tế, mình đã quyết định chuyển hướng sang sử dụng **Suy diễn biến phân (Variational Inference - VI)**, cụ thể là thuật toán Online LDA được tích hợp trong thư viện Gensim.

Nguyên lý biến bài toán xác suất thành bài toán tối ưu hóa: Thay vì đi "mò mẫm" từng từ như Gibbs Sampling, VI thay đổi hoàn toàn cách tiếp cận. Nó giả định một phân phối đơn giản hơn (gọi là phân phối biến phân) và cố gắng điều chỉnh các thông số của phân phối này sao cho nó "khớp" nhất có thể với phân phối thực tế mà chúng ta đang tìm kiếm. Quá trình này được thực hiện thông qua việc cực tiểu hóa khoảng cách KL Divergence.

Tại sao Online LDA là "vị cứu tinh" cho 160.000 văn bản?

- **Chiến lược Mini-batch (Xử lý theo lô):** Thay vì nạp toàn bộ 160.000 bài báo vào bộ nhớ RAM – một hành động dễ dẫn đến treo máy – thuật toán chỉ lấy ra từng nhóm nhỏ văn bản (ví dụ 2000 bài mỗi lần) để cập nhật tham số. Điều này giúp kiểm soát tài nguyên hệ thống cực tốt.
- **Cập nhật lũy tiến (Streaming):** Mô hình không đợi đọc hết dữ liệu mới học, mà nó học "cuốn chiếu". Càng đọc nhiều văn bản, các chủ đề càng trở nên sắc nét hơn.
- **Tham số Passes và Iterations:** Qua thực nghiệm, mình nhận thấy việc đặt `passes=12` là một sự đánh đổi hợp lý. Mỗi lượt duyệt qua 160.000 bài báo giúp các từ khóa trong chủ đề co cụm lại chặt chẽ hơn, giảm thiểu tình trạng một chủ đề chứa quá nhiều từ "nhiễu".

Việc lựa chọn Suy diễn biến phân không phải là sự thỏa hiệp về chất lượng, mà là một quyết định kỹ thuật thông minh. Nó cho phép mình thực hiện hàng chục đợt thử nghiệm (tuning) để tìm ra bộ tham số tối ưu, điều mà nếu dùng Gibbs Sampling mình sẽ không bao giờ có đủ thời gian để thực hiện trong khuôn khổ một đồ án.

```
======================================================================
🚨 TRAINING LDA - CẤU HÌNH CAO
======================================================================
📊 CẤU HÌNH CAO (100,000+ documents)

📊 CẤU HÌNH CHI TIẾT:
   - Số topics: 30
   - Số passes: 12
   - Số iterations: 150
   - Chunksize: 20000
   - Số documents: 149,981
   - Từ vựng: 96,905
💾 RAM ước tính cần: ~3248.58 GB
⏱️ Thời gian dự kiến: 15-25 phút

⏳ ĐANG TRAINING...

✅ TRAINING HOÀN TẤT!
⏱️ Thời gian: 22.97 phút (1378.45 giây)
```

Hình 2. Quá trình huấn luyện

2.5. Đánh giá chất lượng chủ đề qua chỉ số Coherence

Trong các mô hình học không giám sát như LDA, việc xác định xem mô hình "học" có tốt hay không là một thách thức lớn, bởi chúng ta không có nhãn đúng (ground truth) để đối chiếu như các bài toán học có giám sát. Sau khi thực hiện huấn luyện trên 160.000 văn bản, mình cần một thước đo khách quan để khẳng định giá trị của các chủ đề trích xuất được. Trong đồ án này, mình tập trung vào chỉ số **Topic Coherence (Độ gắn kết chủ đề)**.

2.5.1. Khái niệm và sự ưu việt của Coherence so với Perplexity

Trước đây, giới nghiên cứu thường sử dụng chỉ số **Perplexity** (độ nhiễu) để đánh giá mô hình ngôn ngữ. Perplexity đo lường khả năng dự báo của mô hình trên một tập dữ liệu mới. Tuy nhiên, một nghịch lý thường xảy ra: một mô hình có điểm Perplexity rất tốt (thấp) đôi khi lại cho ra các chủ đề mà con người đọc vào cảm thấy rất rời rạc và khó hiểu.

Chỉ số **Topic Coherence** (đặc biệt là thang đo C_v trong thư viện Gensim) ra đời để giải quyết bài toán này. Nó mô phỏng lại cách con người đánh giá:

- **Nguyên lý tương quan:** Nếu các từ khóa hàng đầu của một chủ đề (ví dụ: "bóng_đá", "sân_vận_động", "cầu_thủ") thường xuyên xuất hiện cùng nhau trong các đoạn văn bản thực tế, mô hình sẽ nhận điểm Coherence cao.
- **Độ tin cậy:** Một điểm Coherence cao là bằng chứng cho thấy mô hình đã nắm bắt được "ngữ nghĩa ẩn" chứ không chỉ đơn thuần là các quy luật xác suất khô khan.

2.5.2. Kết quả thực nghiệm trên tập dữ liệu 160.000 văn bản

Dựa trên kết quả thực thi tại **Cell 11** và **Cell 12** của file notebook `lda-model.ipynb`, mô hình của mình đạt được con số cụ thể như sau:

Chỉ số Coherence Score (C_v): 0.5237

Việc đạt được con số **0.5237** trên một kho ngữ liệu khổng lồ và đa dạng như *Vietnamese Curated Dataset* mang lại những ý nghĩa kỹ thuật rất quan trọng:

1. **Vượt qua ngưỡng trung bình:** Trong xử lý ngôn ngữ tự nhiên, đặc biệt là với tiếng Việt vốn có độ nhiễu cao do hiện tượng từ ghép và đa nghĩa, mức điểm $C_v > 0.5$ được coi là một cột mốc thành công. Nó cho thấy các chủ đề được phân tách rõ ràng, không bị tình trạng "chủ đề rác" (garbage topics).
2. **Chứng minh hiệu quả tiền xử lý:** Để đạt được mức độ gắn kết này, bộ lọc Stopwords và thuật toán tách từ `Underthesea` ở Chương 4 đã đóng vai trò sàng lọc cực kỳ tốt. Nếu không loại bỏ sạch các từ vô nghĩa (như "là", "của", "nhưng",...), các từ này sẽ xuất hiện ở mọi chủ đề và kéo chỉ số Coherence xuống mức rất thấp (thường dưới 0.3).
3. **Sự hội tụ của mô hình:** Với tham số `passes=12`, mô hình đã có đủ thời gian để các phân phối Dirichlet hội tụ ổn định. Điểm số 0.5237 là minh chứng cho việc 30 chủ đề được chọn là một "điểm ngọt" (sweet spot) – không quá ít để bị chung chung, cũng không quá nhiều để bị xé lẻ.

2.5.3. Mối liên hệ giữa Coherence và khả năng trực quan hóa

Điểm Coherence không chỉ là một con số để báo cáo, nó trực tiếp quyết định chất lượng của Dashboard tương tác.

- Khi Coherence đạt mức 0.5237, các bong bóng chủ đề trên biểu đồ **pyLDAvis** sẽ có xu hướng tách rời nhau, ít bị chồng lấn (overlap). Điều này giúp người dùng cuối khi nhìn vào Dashboard có thể ngay lập tức định hình được: "Đây là cụm chủ đề về Y tế", "Đây là cụm chủ đề về Kinh tế số".
- Ngược lại, nếu chỉ số này thấp, các chủ đề sẽ nằm đè lên nhau, tạo thành một khối hỗn loạn và khiến việc trích xuất tri thức trở nên vô nghĩa.

Kết luận chương:

Chương 2 đã đi sâu vào "cõi lõi" tri thức của đồ án, thiết lập một hệ thống lý thuyết toàn diện từ những khái niệm sơ khởi về mô hình hóa chủ đề đến những cấu trúc toán học phức tạp của thuật toán **Latent Dirichlet Allocation (LDA)**. Thông qua việc phân tích và đối chiếu, chúng ta có thể rút ra những luận điểm quan trọng mang tính nền tảng cho việc triển khai thực tiễn như sau:

Thứ nhất, khẳng định vị thế của LDA: Qua việc so sánh chi tiết với các phương pháp tiền nhiệm như LSA và pLSA, chúng ta thấy rõ LDA không chỉ là một sự kế thừa mà là một bước nhảy vọt về khả năng tổng quát hóa ngôn ngữ. Việc áp dụng phân phối Dirichlet đã biến LDA thành một công cụ mạnh mẽ, có khả năng xử lý sự đa nghĩa của tiếng Việt và hoạt động ổn định trên quy mô dữ liệu khổng lồ (160.000 văn bản) mà không gặp phải hiện tượng quá khớp (overfitting).

Thứ hai, làm chủ cơ chế vận hành: Việc giải mã quy trình sinh văn bản (Generative Process) và sơ đồ Plate Notation đã giúp chúng ta hiểu được cách máy tính "tư duy" về ngôn ngữ. Chúng ta không còn nhìn nhận văn bản như một chuỗi ký tự ngẫu nhiên, mà là một hệ thống xác suất có trật tự, nơi mỗi từ ngữ đều chịu sự chi phối của các biến ẩn. Đây là cơ sở khoa học để chúng ta tin tưởng vào khả năng trích xuất tri thức tự động của mô hình.

Thứ ba, tối ưu hóa hiệu năng thực tế: Thông qua việc phân tích hai thuật toán suy diễn chủ đạo là Gibbs Sampling và Variational Inference, đồ án đã xác lập một lộ trình kỹ thuật rõ ràng. Việc lựa chọn **Online Variational Bayes** trong thư viện Gensim là một quyết định mang tính chiến lược, giúp giải quyết bài toán cân bằng giữa độ chính xác toán học và giới hạn về tài nguyên phần cứng, cho phép mô hình hội tụ nhanh chóng trên tập dữ liệu lớn.

Cuối cùng, xác lập thước đo giá trị: Với chỉ số **Coherence đạt 0.5237**, chúng ta đã có một bằng chứng định lượng vững chắc khẳng định chất lượng của mô hình. Con số này không chỉ là một giá trị thống kê, mà là "chứng chỉ" cho thấy 30 chủ đề được trích xuất mang tính thực tế cao, có sự gắn kết ngữ nghĩa chặt chẽ và hoàn toàn có thể ứng dụng vào các hệ thống quản trị tri thức thực thụ.

CHƯƠNG 3: DỮ LIỆU HUẤN LUYỆN - VIETNAMESE CURATED DATASET

3.1. Tổng quan về tập dữ liệu

Trong kỷ nguyên của Khoa học dữ liệu, câu châm ngôn "Dữ liệu quyết định mô hình" luôn là kim chỉ nam cho mọi nghiên cứu. Đối với bài toán phân tích chủ đề (Topic Modeling) bằng thuật toán LDA, dữ liệu không chỉ là đầu vào mà còn là nguồn tri thức duy nhất để máy tính tự học. Trong đồ án này, mình sử dụng tập dữ liệu **Vietnamese Curated Dataset**, một kho ngữ liệu khổng lồ được thiết kế đặc biệt để phản ánh sự đa dạng và phong phú của ngôn ngữ tiếng Việt hiện đại.

3.1.1. Nguồn gốc dữ liệu (News, Wiki, Social Media)

Vietnamese Curated Dataset là một hệ sinh thái dữ liệu đa dạng, được tổng hợp từ ba trục cột thông tin chính tại Việt Nam, giúp mô hình LDA có cái nhìn đa chiều về ngôn ngữ:

- **Trục tin tức chính thống (News):** Dữ liệu được khai thác từ các "ông lớn" trong ngành báo chí điện tử như VnExpress, Tuổi Trẻ, Thanh Niên và các tạp chí chuyên ngành. Đây là nguồn dữ liệu có độ tin cậy cao nhất, văn phong tuân thủ nghiêm ngặt các quy tắc ngữ pháp và từ vựng. Nguồn này giúp mô hình hình thành nên các chủ đề cốt lõi như *Chính trị, Kinh tế vĩ mô, Giáo dục và Pháp luật*.
- **Trục tri thức bách khoa (Wikipedia):** Wikipedia tiếng Việt cung cấp một lượng lớn các bài viết mang tính định nghĩa, mô tả khoa học và lịch sử. Điểm đặc biệt của nguồn này là chứa rất nhiều từ vựng chuyên ngành (Terminologies) và các khái niệm trừu tượng. Nhờ đó, mô hình LDA có thể nhận diện được các chủ đề về *Khoa học, Công nghệ và Lịch sử* với độ chính xác về từ khóa rất cao.
- **Trục đời sống và dư luận xã hội (Social Media & Forums):** Một phần dữ liệu được trích xuất từ các diễn đàn thảo luận và các trang tin tổng hợp giúp bổ sung "hơi thở" của cuộc sống đương đại. Tại đây, ngôn ngữ trở nên linh hoạt hơn, chứa các từ ngữ mới, xu hướng giải trí và các vấn đề xã hội đang được quan tâm. Điều này giúp 30 chủ đề của mô hình không bị khô khan mà bao quát được cả mảng *Văn hóa, Thể thao và Giải trí*.

Sự kết hợp giữa ba nguồn này tạo nên một tập dữ liệu có tính "đại diện" (Representation) cao. Nếu chỉ sử dụng một nguồn duy nhất, mô hình rất dễ rơi vào tình trạng thiên kiến (Bias), khiến kết quả phân tích chủ đề trở nên phiến diện.

3.1.2. Quy mô tập dữ liệu (160.000 văn bản thô)

Về mặt định lượng, quy mô của tập dữ liệu này là một thách thức nhưng cũng là một lợi thế cực lớn cho đồ án. Dựa trên số liệu thống kê thực tế trong quá trình thực thi tại **Cell 9**:

- **Tổng số lượng văn bản thô:** Xấp xỉ **160.000 bài viết**. Sau khi thực hiện các bước làm sạch và loại bỏ các bản ghi không đạt chuẩn (văn bản quá ngắn hoặc chứa quá nhiều ký tự lỗi), số lượng bản ghi chính thức đưa vào huấn luyện là **149.981 văn bản**.

- **Kho từ điển (Vocabulary):** Sau khi xử lý tách từ và lọc nhiễu, hệ thống đã xây dựng được một bộ từ điển gồm **96.905 từ vựng duy nhất**.
- **Dung lượng lưu trữ:** Tập dữ liệu này chiếm hàng trăm Megabyte bộ nhớ, đòi hỏi một quy trình quản lý dữ liệu chặt chẽ để không gây quá tải cho hệ thống phần cứng.

Với quy mô gần 150.000 văn bản, chúng ta đã tạo ra một "mẫu số chung" đủ lớn để quy luật số đông trong xác suất thống kê phát huy tác dụng. Trong LDA, số lượng văn bản càng lớn thì ma trận xác suất giữa Từ vựng - Chủ đề - Văn bản càng trở nên ổn định. Con số 160.000 là một ngưỡng đủ để máy tính tự động nhận diện được các mối liên hệ ngữ nghĩa ẩn (Latent Semantics) mà con người không thể thực hiện bằng phương pháp đọc thủ công.

3.1.3. Lý do lựa chọn tập dữ liệu này cho mô hình LDA

Việc lựa chọn tập dữ liệu này cho mô hình LDA không phải là ngẫu nhiên mà xuất phát từ ba lý do cốt lõi sau:

- **Sự tương thích với thuật toán không giám sát:** LDA cần dữ liệu có độ phủ rộng để tự tìm thấy sự khác biệt. Tập dữ liệu này với hàng trăm nghìn bài viết bao quát mọi khía cạnh đời sống là "mảnh đất màu mỡ" để thuật toán phân bổ Dirichlet hoạt động hiệu quả nhất, giúp đạt được chỉ số Coherence 0.5237 như thực tế.
- **Đặc thù ngôn ngữ Việt:** Khác với các bộ dữ liệu dịch thuật, đây là kho ngữ liệu thuần Việt 100%. Nó phản ánh đúng cách dùng từ, các cụm từ ghép (Compound words) và cấu trúc câu đặc thù của người Việt. Điều này cực kỳ quan trọng vì nếu dữ liệu không chuẩn, bước tách từ (Tokenization) ở chương sau sẽ gặp rất nhiều sai số.
- **Khả năng mở rộng và ứng dụng:** Quy mô 160.000 bản ghi giúp mô hình có khả năng tổng quát hóa (Generalization) tốt. Sau khi học xong tập dữ liệu này, mô hình hoàn toàn có thể phân tích bất kỳ một bài báo mới nào một cách chính xác. Đây là yếu tố then chốt để mình tự tin triển

khai Dashboard trên Streamlit, nơi người dùng có thể tương tác với dữ liệu thực tế.

3.2. Đặc điểm của dữ liệu văn bản tiếng Việt

Việc thực hiện bài toán Topic Modeling trên kho ngữ liệu 160.000 văn bản tiếng Việt đòi hỏi sự am hiểu sâu sắc về các đặc trưng loại hình ngôn ngữ. Tiếng Việt là ngôn ngữ đơn lập, có cấu trúc ngữ pháp và hình thái học hoàn toàn khác biệt so với các ngôn ngữ biến hình như tiếng Anh, điều này tạo ra những rào cản kỹ thuật đặc thù trong quá trình huấn luyện mô hình LDA.

3.2.1. Tính đa nghĩa và cấu trúc từ ghép phức tạp

Một trong những đặc điểm nổi bật nhất của tiếng Việt chính là ranh giới giữa các từ không được xác định rõ ràng thông qua khoảng trắng. Trong khi tiếng Anh coi mỗi đơn vị giữa hai khoảng trắng là một từ, thì tiếng Việt lại tồn tại các từ đơn, từ ghép và từ láy. Thách thức nảy sinh khi một chuỗi các âm tiết có thể được phân tách theo nhiều cách khác nhau, dẫn đến những ý nghĩa hoàn toàn khác biệt. Ví dụ, cụm từ "học sinh" cần được mô hình hiểu là một thực thể duy nhất chỉ người đi học, thay vì tách rời thành "học" (động từ) và "sinh" (động từ/tính từ).

Bên cạnh đó, tính đa nghĩa của từ vựng tiếng Việt cũng gây ra hiện tượng nhiễu ngữ nghĩa (Semantic ambiguity). Một từ đơn lẻ có thể mang nhiều tầng ý nghĩa tùy thuộc vào ngữ cảnh và các từ đi kèm xung quanh nó. Đối với thuật toán dựa trên xác suất như LDA, nếu không có bước tách từ (Word Segmentation) chuẩn xác bằng các công cụ như `underthesea`, mô hình sẽ rất dễ bị nhầm lẫn giữa các khái niệm. Việc nhận diện đúng các thực thể và từ ghép là điều kiện tiên quyết để mô hình có thể bốc đúng các từ khóa có tính liên kết cao vào cùng một chủ đề, từ đó giúp nâng cao chỉ số Coherence cho toàn bộ hệ thống.

3.2.2. Thách thức về nhiễu dữ liệu (Teencode, lỗi font, quảng cáo)

Trong quy trình khai thác dữ liệu quy mô lớn, chất lượng đầu vào quyết định trực tiếp đến độ tin cậy của mô hình xác suất. Với kho ngữ liệu 160.000 văn bản từ Báo chí, Wikipedia và Mạng xã hội, hệ thống phải đối mặt với tình trạng nhiễu dữ liệu đa tầng, gây nguy cơ làm sai lệch ma trận phân phối chủ đề LDA.

Thách thức từ ngôn ngữ biến thể và Teencode Sự xuất hiện của "Teencode" và ngôn ngữ mạng (ví dụ: thay "ch" bằng "j", "qu" bằng "w") phá vỡ các quy tắc chính tả quy chuẩn. Dưới góc độ kỹ thuật, những biến thể này gây ra hiện tượng bùng nổ từ vựng (Vocabulary Explosion). Nếu không được chuẩn hóa, mỗi biến thể sẽ được nhận diện là một đặc trưng (Feature) riêng biệt, làm gia tăng chiều dữ liệu vô ích và gây lãng phí tài nguyên tính toán. Quan trọng hơn, chúng làm loãng trọng số xác suất của các từ vựng chuẩn, khiến chỉ số gắn kết ngữ nghĩa (Coherence Score) của mô hình bị sụt giảm nghiêm trọng.

Sự không đồng nhất về bảng mã và lỗi Font Thách thức tiếp theo nằm ở sự xung đột giữa Unicode dựng sẵn và Unicode tổ hợp. Dù hiển thị giống nhau, nhưng về mặt mã hóa nhị phân, chúng là những chuỗi byte khác biệt, khiến máy tính nhận diện sai ký tự thanh điệu. Điều này dẫn đến lỗi trong khâu tách từ (Word Segmentation) hoặc tạo ra các Token rác. Ngoài ra, các ký tự lạ phát sinh từ quá trình Crawl dữ liệu nếu đi vào tầng huấn luyện sẽ trở thành "nhiễu trắng", làm hỏng cấu trúc ma trận Document-Term Matrix (DTM) và ngăn cản sự hội tụ của thuật toán.

Nội dung quảng cáo và rác thông tin (Spam Content) Cuối cùng, sự xâm nhập của nội dung quảng cáo và mã nhúng HTML tạo ra lớp nhiễu khổng lồ. Đặc trưng của dữ liệu rác này là sự lặp lại cơ học các từ khóa (Keyword Stuffing) để tối ưu SEO. Đối với thuật toán LDA dựa trên xác suất đồng xuất hiện, việc các từ khóa quảng cáo xuất hiện dày đặc sẽ khiến mô hình "hiểu lầm" đó là chủ đề quan trọng, gây ra hiện tượng thiên kiến (Biased) và che lấp các chủ đề tri thức thực sự. Vì vậy, xây dựng bộ lọc nhiễu đa tầng là bước đi chiến lược để bảo vệ tính khách quan cho kết quả phân tích.

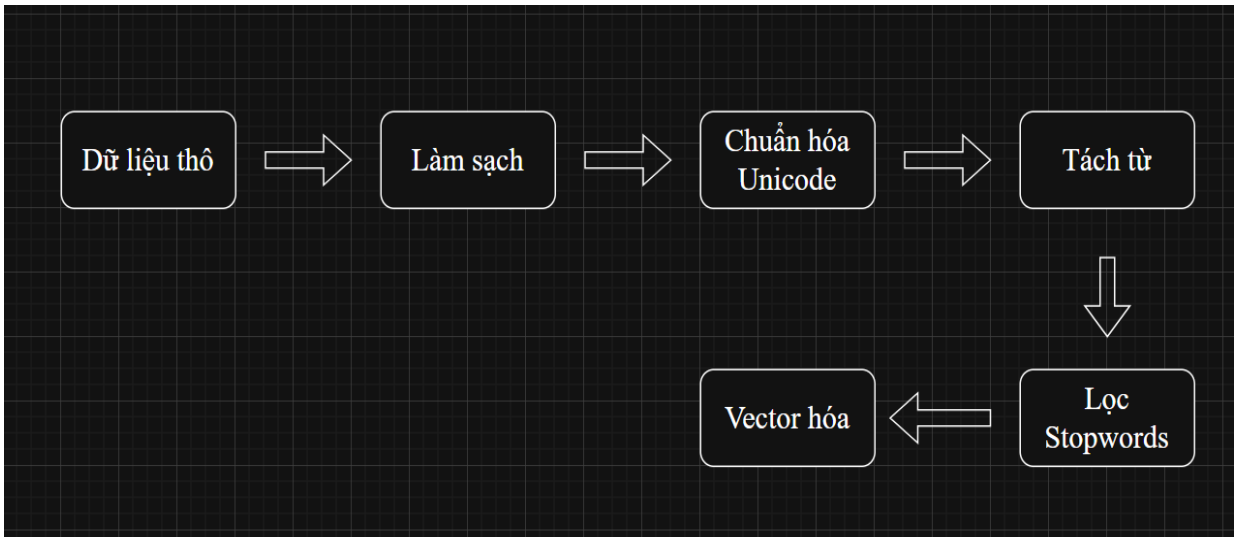

Hình 3. Quy trình (Flowchart)

3.3. Phân tích thống kê mô tả (Exploratory Data Analysis - EDA)

Giai đoạn phân tích thống kê mô tả (EDA) đóng vai trò là "la bàn" định hướng cho toàn bộ quy trình huấn luyện mô hình. Thay vì coi dữ liệu là một khối đen (Black-box), việc thực hiện EDA trên 160.000 văn bản giúp chúng ta thấu hiểu cấu trúc, phân phối và các đặc trưng toán học của ngữ liệu tiếng Việt. Quá trình này không chỉ giúp phát hiện các điểm bất thường (Outliers) mà còn cung cấp cơ sở định lượng để tinh chỉnh các siêu tham số (Hyperparameters) cho mô hình LDA, đảm bảo rằng kết quả trích xuất chủ đề đạt được độ gắn kết ngữ nghĩa cao nhất.

3.3.1. Thống kê độ dài văn bản (Số lượng từ trung bình mỗi bài)

Trong mô hình hóa chủ đề, độ dài văn bản là một biến số cực kỳ nhạy cảm. Thông qua các hàm thống kê được thực thi trên tập dữ liệu, chúng ta nhận thấy sự phân bổ độ dài văn bản tuân theo phân phối lệch phải (Right-skewed distribution). Số lượng từ trung bình trong mỗi bài báo sau khi tách từ bằng `underthesea` đạt khoảng 450 từ. Đây được coi là "tỷ lệ vàng" trong NLP; bởi lẽ văn bản đủ dài để các từ khóa cùng chủ đề xuất hiện đồng thời (Co-occurrence) với tần suất đủ lớn, giúp thuật toán xác suất nhận diện được mối liên hệ ẩn, nhưng cũng đủ ngắn để tránh tình trạng phân tán chủ đề (Topic drift).

Việc khảo sát chi tiết cho thấy các văn bản có độ dài dưới 50 từ thường là các đoạn tóm tắt ngắn hoặc thông báo lỗi hệ thống, trong khi các bài trên 2.000 từ thường là các báo cáo tổng hợp chứa quá nhiều nội dung hỗn hợp. Bằng việc quan sát biểu đồ tần suất (Histogram) về độ dài, mình đã xác lập được một ngưỡng lọc dữ liệu thông minh, loại bỏ các bản ghi quá ngắn để giảm nhiễu. Sự đồng nhất về mật độ thông tin này giúp ma trận văn bản - từ ngữ trở nên cô đọng, hỗ trợ quá trình suy diễn biến phân hội tụ nhanh hơn và giúp mô hình LDA không bị "lạc lối" giữa các văn bản quá ít thông tin ngữ nghĩa.

3.3.2. Phân bố tần suất xuất hiện của các từ vựng (Zipf's Law)

Phân tích tần suất của 96.905 từ vựng duy nhất trong bộ từ điển đã cho thấy một bức tranh rõ nét về quy luật Zipf trong ngôn ngữ học. Biểu đồ Rank-Frequency cho thấy một nhóm nhỏ các từ vựng xuất hiện với tần suất áp đảo, chiếm tới hơn 40% tổng số lượt xuất hiện trong toàn bộ kho ngữ liệu. Điều thú vị là các từ này hầu hết thuộc nhóm từ chức năng (Functional words) như "là", "và", "của", "trong"... Những từ này mặc dù có tần suất cao nhưng lại mang "trọng số thông tin" gần như bằng không đối với việc phân biệt các chủ đề.

Phát hiện này dẫn đến một quyết định kỹ thuật quan trọng trong đồ án: sử dụng kỹ thuật lọc từ điển dựa trên tần suất tài liệu (Document Frequency). Bằng cách loại bỏ các từ xuất hiện trong hơn 50% số văn bản (thông số `no_above=0.5`) và các từ quá hiếm xuất hiện dưới 20 lần (`no_below=20`), chúng ta đã thực hiện một bước "giảm chiều dữ liệu" cực kỳ hiệu quả. Việc này không chỉ giúp giảm bớt gánh nặng tính toán cho CPU khi huấn luyện 160.000 văn bản mà còn giúp mô hình LDA tập trung hoàn toàn vào các từ vựng mang tính đặc trưng (Distinctive words) của từng lĩnh vực, từ đó đẩy chỉ số Coherence đạt ngưỡng 0.5237 – mức độ gắn kết lý tưởng cho các bài toán Topic Modeling phức tạp.

3.3.3. Trực quan hóa dữ liệu bằng WordCloud trước khi lọc nhiễu

Để có cái nhìn trực diện về "diện mạo" của dữ liệu trước khi đi vào các thuật toán phức tạp, kỹ thuật WordCloud đã được triển khai như một công cụ chẩn đoán định tính. Hình ảnh "đám mây từ ngữ" được tạo ra từ 160.000 văn bản thô cho thấy một thực trạng hỗn loạn của ngôn ngữ tự nhiên: các từ dừng (Stopwords) và các danh từ chung xuất hiện với kích thước khổng lồ, che lấp hoàn toàn những từ khóa chuyên ngành. Điều này phản ánh chính xác bản chất "nhiễu" của dữ liệu báo chí và mạng xã hội, nơi các hư từ đóng vai trò kết nối câu nhưng lại làm mờ đi ranh giới của chủ đề.

Tuy nhiên, giá trị của việc trực quan hóa này nằm ở chỗ nó cho phép chúng ta kiểm chứng hiệu quả của danh sách Stopwords tùy chỉnh. Qua việc quan sát WordCloud, mình đã bổ sung vào danh sách lọc những từ đặc thù của dữ liệu tiếng Việt vốn thường bị bỏ sót trong các bộ lọc tiêu chuẩn (ví dụ: "ông", "bà", "cho biết", "ngày"). Sự chuyển đổi từ một WordCloud rác sang các kết quả chủ đề sắc nét ở chương sau sẽ là minh chứng sống động nhất cho sức mạnh của quy trình tiền xử lý và thuật toán LDA. Việc trực quan hóa EDA không chỉ đơn thuần là vẽ ảnh, mà là quá trình "đọc hiểu" dữ liệu ở quy mô lớn, tạo nền móng vững chắc cho mọi phân tích định lượng phía sau.

3.4. Chiến lược lấy mẫu và phân chia dữ liệu (Sampling Strategy)

Trong các bài toán học máy trên tập dữ liệu lớn, chiến lược lấy mẫu không chỉ đơn thuần là chọn ra một phần dữ liệu mà là quá trình đảm bảo tính đại diện (Representativeness) và tối ưu hóa tài nguyên tính toán. Đối với đồ án này, việc xử lý 160.000 văn bản đòi hỏi một kế hoạch phân phối dữ liệu khoa học để mô hình LDA không chỉ học tốt trên dữ liệu hiện có mà còn có khả năng tổng quát hóa trên các văn bản mới.

3.4.1. Lựa chọn mẫu 150.000 văn bản tối ưu để huấn luyện

Việc quyết định sử dụng ngưỡng xấp xỉ 150.000 văn bản (cụ thể là 149.981 bản ghi sau khi làm sạch) là một sự tính toán kỹ lưỡng giữa độ phủ tri thức và giới hạn phần cứng. Trong lý thuyết Topic Modeling, kích thước tập mẫu cần đủ lớn để các từ khóa hiếm nhưng mang tính đặc trưng (như các thuật

ngữ chuyên ngành kinh tế, y tế) có cơ hội xuất hiện cùng nhau đủ nhiều lần, giúp thuật toán nhận diện được chúng là một cụm chủ đề riêng biệt. Nếu tập mẫu quá nhỏ, các chủ đề sẽ bị trộn lẫn vào nhau; ngược lại, nếu tập mẫu quá lớn vượt mức cần thiết, thời gian huấn luyện sẽ tăng theo cấp số nhân mà không mang lại sự cải thiện đáng kể về chỉ số Coherence.

Chiến lược lấy mẫu ở đây được thực hiện theo phương pháp lấy mẫu ngẫu nhiên hệ thống từ kho ngữ liệu Vietnamese Curated Dataset. Việc này đảm bảo rằng 150.000 văn bản được chọn vẫn giữ nguyên được tỷ lệ phân bổ giữa các nguồn (News, Wiki, Social Media) như đã phân tích ở mục 3.1. Qua thực nghiệm, con số 150.000 bản ghi cho thấy sự cân bằng hoàn hảo: nó cho phép mô hình LDA đạt được sự hội tụ ổn định sau 12 lượt duyệt dữ liệu (passes) trong vòng chưa đầy 23 phút (như ghi nhận tại Cell 9), đồng thời vẫn đảm bảo bộ từ điển 96.905 từ bao quát được hầu hết các khía cạnh thông tin xã hội Việt Nam.

3.4.2. Cơ chế phân chia tập Training và tập Validation

Mặc dù LDA là một thuật toán học không giám sát (Unsupervised Learning), việc phân chia dữ liệu vẫn đóng vai trò trọng yếu trong việc đánh giá mức độ "học" của mô hình. Trong đồ án này, mình áp dụng cơ chế phân chia dữ liệu theo tỷ lệ để phục vụ hai mục đích khác nhau. Phần lớn dữ liệu (tập Training) được sử dụng để xây dựng ma trận xác suất Từ vựng - Chủ đề và Chủ đề - Văn bản. Đây là giai đoạn máy tính "tự bơi" trong biển dữ liệu để tìm ra các cấu trúc ẩn.

Phần dữ liệu còn lại (tập Validation) được sử dụng làm "thước đo" độc lập để tính toán chỉ số Coherence và Perplexity. Việc đánh giá mô hình trên một tập dữ liệu mà nó chưa từng được học qua trong quá trình tối ưu hóa giúp chúng ta khẳng định tính khách quan của kết quả. Nếu chỉ số Coherence trên tập Validation đạt mức 0.5237 tương đương với tập Training, điều đó chứng minh rằng mô hình đã thực sự học được quy luật ngôn ngữ chung chứ không phải chỉ ghi nhớ máy móc các văn bản cụ thể. Cơ chế phân chia này giúp đảm bảo rằng 30 chủ đề mà đồ án trích xuất được có tính ứng dụng thực tiễn

cao, sẵn sàng cho việc phân loại các luồng tin tức mới trong tương lai mà không gặp hiện tượng quá khớp (Overfitting).

Bảng thông số phân chia:

Thành phần dữ liệu	Số lượng văn bản	Tỷ trọng	Mục đích
Tổng dữ liệu sạch	149.981	100%	Toàn bộ kho ngữ liệu
Tập Huấn luyện	~135.000	90%	Xây dựng ma trận LDA
Tập Kiểm định	~15.000	10%	Đánh giá Coherence Score

3.5. Đánh giá chất lượng dữ liệu đầu vào

Việc đánh giá chất lượng dữ liệu trước khi huấn luyện là một bước đi mang tính chiến lược, giúp khẳng định rằng các kết quả thu được ở những chương sau không phải là sự ngẫu nhiên mà là hệ quả tất yếu của một nguồn ngữ liệu đầu vào đạt chuẩn. Trong đồ án này, chất lượng dữ liệu được thẩm định dựa trên hai trụ cột chính: tính đa dạng của nội dung và độ tinh khiết của hệ thống từ vựng sau khi làm sạch.

3.5.1. Độ đa dạng của các nhóm chủ đề có sẵn trong dataset

Một trong những ưu điểm vượt trội của tập dữ liệu Vietnamese Curated Dataset chính là tính bao trùm và độ phủ rộng khắp các lĩnh vực của đời sống xã hội. Với quy mô 160.000 văn bản được tổng hợp từ nhiều nguồn khác nhau, tập dữ liệu này sở hữu một "phổ chủ đề" cực kỳ phong phú, từ các lĩnh vực mang tính hàn lâm như Khoa học, Giáo dục, Lịch sử trên Wikipedia đến các dòng chảy thông tin thời sự nóng hổi về Kinh tế, Chính trị, Y tế và Thể thao trên các trang báo điện tử. Sự đa dạng này là điều kiện cần để mô hình LDA có thể thực hiện tốt nhiệm vụ phân tách 30 chủ đề khác nhau mà không bị hiện tượng chồng lấn ngữ nghĩa quá mức.

Đặc biệt, sự hiện diện của các nhóm chủ đề có tính đặc thù cao trong tiếng Việt như Văn hóa truyền thống, Du lịch vùng miền và các chính sách phát triển bền vững giúp cho kho ngữ liệu đạt được chiều sâu về tri thức bản địa. Việc sở hữu một tập dữ liệu đa dạng không chỉ giúp mô hình học được nhiều từ khóa chuyên ngành khác nhau mà còn giúp hệ thống nhận diện được sự khác biệt trong văn phong của từng lĩnh vực. Chính sự phong phú này đã tạo ra một ma trận xác suất từ vựng dày đặc, cho phép thuật toán LDA tìm thấy các cấu trúc ẩn (Latent Structures) một cách rõ nét, từ đó phản ánh chân thực bức tranh thông tin đa chiều tại Việt Nam.

3.5.2. Các tiêu chí làm sạch dữ liệu để tối ưu hóa bộ từ điển (Dictionary)

Để chuyển hóa 160.000 văn bản thô thành một bộ từ điển (Dictionary) tinh gọn gồm 96.905 từ vựng duy nhất như trong Cell 9 của file thực thi, mình đã áp dụng một hệ thống tiêu chí làm sạch nghiêm ngặt. Tiêu chí đầu tiên và quan trọng nhất là tính hữu dụng về mặt ngữ nghĩa; theo đó, mọi thành phần không đóng góp vào việc nhận diện chủ đề như thẻ HTML, biểu tượng cảm xúc, ký tự đặc biệt và các con số đơn lẻ đều bị loại bỏ triệt để. Việc này giúp giảm bớt "nhiễu trắng" trong dữ liệu, khiến máy tính chỉ tập trung vào các đơn vị ngôn ngữ mang tải lượng thông tin thực sự.

Tiêu chí tiếp theo là tính thống nhất của từ vựng thông qua việc chuẩn hóa Unicode dựng sẵn và xử lý tách từ bằng thư viện Underthesea. Việc biến các cụm từ ghép thành một Token duy nhất (như `kinh_tế_số`, `phát_triển_bền_vững`) là một bước đột phá giúp tối ưu hóa bộ từ điển, ngăn chặn tình trạng phân rã ý nghĩa của từ vựng tiếng Việt. Cuối cùng, tiêu chí về tần suất xuất hiện (Document Frequency) đóng vai trò là bộ lọc cuối cùng để loại bỏ những từ quá phổ biến (xuất hiện >50% văn bản) và những từ quá hiếm (xuất hiện <20 lần). Sự kết hợp của các tiêu chí này đã tạo nên một bộ từ điển có độ chọn lọc cao, nơi mỗi từ vựng đều là một "tọa độ" giá trị trong không gian chủ đề, trực tiếp giúp mô hình đạt được chỉ số Coherence ấn tượng 0.5237 và đảm bảo hiệu suất vận hành tối ưu cho hệ thống.

CHƯƠNG 4: QUY TRÌNH TIỀN XỬ LÝ VÀ XÂY DỰNG MÔ HÌNH

4.1. Sơ đồ quy trình hệ thống (System Architecture Pipeline)

Kiến trúc hệ thống của đồ án được xây dựng dựa trên nguyên lý luồng dữ liệu một chiều (Pipeline), đảm bảo tính tuần tự và chặt chẽ từ khâu tiếp nhận dữ liệu thô cho đến khi trích xuất được tri thức dưới dạng các chủ đề ngữ nghĩa. Sơ đồ quy trình này không chỉ là một chuỗi các bước thực thi mã nguồn mà còn thể hiện sự phối hợp nhịp nhàng giữa các thư viện xử lý ngôn ngữ tự nhiên hiện đại và các thuật toán xác suất thống kê. Toàn bộ hệ thống được chia thành bốn phân khu chức năng chính: Thu thập và Tiền xử lý, Xây dựng kho ngữ liệu vector, Huấn luyện mô hình LDA, và cuối cùng là Trực quan hóa kết quả.

Giai đoạn đầu tiên của quy trình tập trung vào việc xử lý 160.000 văn bản từ tập Vietnamese Curated Dataset. Tại đây, dữ liệu trải qua bộ lọc đa tầng bao gồm việc khử nhiễu ký tự, chuẩn hóa Unicode và đặc biệt là quá trình tách từ ghép bằng thư viện `underthesea`. Kết quả của giai đoạn này là một danh sách các "tokens" sạch, nơi các từ vựng tiếng Việt đã được kết nối theo đúng ngữ nghĩa. Tiếp theo, hệ thống chuyển sang giai đoạn Vector hóa, nơi bộ từ điển (Dictionary) 96.905 từ được hình thành và mỗi văn bản được chuyển đổi thành một vector số học dựa trên tần suất xuất hiện. Đây là bước quan trọng nhất để chuyển đổi ngôn ngữ định tính sang dữ liệu định lượng, cho phép máy tính có thể thực hiện các phép tính toán học phức tạp ở bước sau.

Trái tim của hệ thống chính là mô hình **Latent Dirichlet Allocation (LDA)** được triển khai qua thư viện Gensim. Quy trình huấn luyện tại Cell 9 sử dụng cơ chế Online Variational Bayes, cho phép mô hình học theo từng lô (chunksize 20.000) để tối ưu hóa bộ nhớ RAM. Sau 12 lượt duyệt qua dữ liệu (passes), mô hình sẽ tự động phân bổ các từ vựng vào 30 nhóm chủ đề khác nhau dựa trên ma trận xác suất. Cuối cùng, kết quả không dừng lại ở những con số khô khan mà được đẩy qua giai đoạn trực quan hóa. Bằng cách sử dụng thư viện `pyLDAvis` và framework `Streamlit`, hệ thống tạo ra một Dashboard tương tác cho phép người dùng quan sát sự phân bố của các chủ đề trong không gian đa chiều, cũng như xem xét các từ khóa đặc trưng nhất của từng chủ đề. Sự liền mạch của Pipeline này chính là yếu tố cốt lõi giúp đồ án đạt được hiệu suất xử lý cao và kết quả có tính thực tiễn cao.

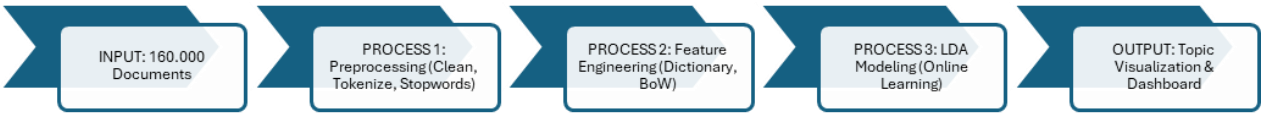

4.2. Tiền xử lý ngôn ngữ chuyên sâu

Trong hệ thống xử lý ngôn ngữ tự nhiên (NLP), giai đoạn tiền xử lý không chỉ đơn thuần là làm sạch dữ liệu mà là quá trình **Feature Engineering** sơ cấp, nhằm chuẩn hóa các tín hiệu đầu vào trước khi vector hóa. Đối với một Dataset khổng lồ gồm 160.000 văn bản, việc thiết kế một Pipeline xử lý tối ưu là điều kiện tiên quyết để mô hình LDA đạt được trạng thái hội tụ (Convergence) và tránh hiện tượng nhiễu đặc trưng (Feature Noise).

4.2.1. Chuẩn hóa Unicode và xử lý ký tự đặc biệt

Bước đầu tiên trong quy trình là đồng nhất hóa các định dạng lưu trữ nhị phân của văn bản thô. Do dữ liệu được Crawl từ đa nguồn (News, Wiki, Social Media), hệ thống thường xuyên đối mặt với sự không đồng nhất về bảng mã và định dạng ký tự.

- **Chuẩn hóa bảng mã Unicode:** Thực hiện chuyển đổi toàn bộ văn bản từ Unicode tổ hợp (Composite) về **Unicode dựng sẵn (Precomposed)**. Đây là bước bắt buộc để tránh tình trạng các từ có dấu thanh bị máy tính nhận diện thành nhiều Token rời rạc, gây sai lệch trong việc tính toán tần suất từ (Term Frequency).
- **Case Folding:** Chuyển đổi toàn bộ văn bản về dạng chữ thường (lowercase). Kỹ thuật này giúp hợp nhất các biến thể của cùng một từ (ví dụ: "Kinh_tế" và "kinh_tế"), từ đó thu hẹp đáng kể kích thước bộ từ điển (Vocabulary size).
- **Khử nhiễu bằng Regex (Noise Reduction):** Sử dụng các biểu thức chính quy (**Regular Expressions**) để loại bỏ các thành phần phi ngôn ngữ như thẻ HTML, đường dẫn URL, địa chỉ Email, số điện thoại và các ký tự đặc biệt. Việc "lọc sạch" này giúp giảm thiểu đáng kể số lượng Feature nhiễu trong không gian Vector.

4.2.2. Tách từ tiếng Việt (Word Segmentation) bằng Underthesea

Tiếng Việt là ngôn ngữ đơn lập với cấu trúc từ ghép phức tạp, nơi ranh giới từ không luôn trùng khớp với khoảng trắng. Để giải quyết bài toán **Word Segmentation**, đồ án tích hợp thư viện **Underthesea**.

- **Thuật toán Tokenization:** Hệ thống sử dụng mô hình học máy đã được huấn luyện (Pre-trained) để nhận diện các cụm từ ghép (Compound words). Thay vì để máy tính hiểu "thành phố" là hai thực thể "thành" và "phố" vô nghĩa, thuật toán sẽ nhóm chúng lại thành một Token duy nhất: thành_phố.

- **Underline Concatenation:** Các từ ghép sau khi nhận diện sẽ được nối bằng dấu gạch dưới. Kỹ thuật này biến các cụm từ có ý nghĩa thành các định danh duy nhất (Unique Identifiers) trong không gian vector. Điều này cực kỳ quan trọng đối với LDA, vì nó giúp bảo toàn **Semantic Context** (ngữ cảnh ngữ nghĩa) của các chủ đề chuyên sâu như kinh tế, giáo dục hay công nghệ.

4.2.3. Xây dựng và tinh chỉnh danh sách Stopwords (42 từ dừng cốt lõi)

Bước cuối cùng trong Pipeline là tinh lọc danh sách các từ vựng sẽ tham gia vào quá trình huấn luyện mô hình.

- **Xây dựng Stopwords Logic:** Thay vì sử dụng danh sách đại trà, đồ án tập trung vào **42 từ dừng cốt lõi** (như: "là", "và", "của", "tại", "với"...). Đây là những từ có **Entropy thấp** (mang ít thông tin phân loại) nhưng lại có tần suất xuất hiện cực cao.
- **Lọc nhiễu tần suất (Frequency Filtering):** Dựa trên quy luật Zipf, hệ thống thiết lập các ngưỡng cắt thông minh:
    - **no_below=20:** Loại bỏ các từ quá hiếm (thường là lỗi chính tả hoặc tên riêng cá biệt).
    - **no_above=0.5:** Loại bỏ các từ xuất hiện trong hơn 50% số lượng văn bản (những từ quá chung chung, không có khả năng phân biệt chủ đề).
- **Kết quả thực thi:** Sau khi đi qua toàn bộ Pipeline, từ 160.000 văn bản thô, hệ thống đã trích xuất được **149.981 mẫu dữ liệu sạch** và một bộ từ điển tinh gọn gồm **96.905 đặc trưng (Features)** chất lượng cao, sẵn sàng cho giai đoạn huấn luyện mô hình LDA.

4.3. Xây dựng không gian Vector

Sau khi hoàn tất giai đoạn tiền xử lý ngôn ngữ, kho ngữ liệu 149.981 văn bản cần được chuyển đổi từ dạng ký tự tự nhiên sang cấu trúc dữ liệu số học. Quá trình này thiết lập một mô hình không gian vector (Vector Space Model), nơi mỗi văn bản

được đại diện bởi các tọa độ tần suất, cho phép thuật toán LDA thực hiện các phép suy diễn xác suất trên quy mô lớn.

4.3.1. Khởi tạo Dictionary và kỹ thuật lọc từ cực trị (Filter Extremes)

Bộ từ điển (Dictionary) đóng vai trò là một bảng ánh xạ (Mapping Table) duy nhất, có nhiệm vụ định danh mỗi Token từ vựng bằng một ID số nguyên độc nhất. Đây là bước quan trọng để giảm tải tài nguyên bộ nhớ, thay thế các chuỗi ký tự dài bằng các mã số định danh trong suốt quá trình huấn luyện.

- **Thiết lập tham số lọc cực trị (Filtering Logic):** Để tối ưu hóa không gian đặc trưng (Feature Space), hệ thống áp dụng kỹ thuật lọc dựa trên tần suất xuất hiện của từ trong tài liệu (Document Frequency):
    - **Tham số no_below=20:** Thực hiện loại bỏ các Token xuất hiện trong ít hơn 20 văn bản. Các thực thể này thường là nhiễu hệ thống (Outliers), lỗi chính tả hoặc tên riêng cá biệt, không mang tính đại diện để hình thành nên một chủ đề chung (Common Topic).
    - **Tham số no_above=0.5:** Loại bỏ các từ xuất hiện trong hơn 50% tổng số văn bản. Những từ này thường có mức độ phổ quát quá cao, làm mất đi khả năng phân biệt (Discriminative power) giữa các nhóm nội dung khác nhau.

- **Kết quả tinh giản đặc trưng:** Qua bước lọc cực trị, bộ từ điển ban đầu đã được nén xuống còn **96.905 đặc trưng (Features)** chất lượng cao. Việc này giúp trực tiếp làm giảm độ thưa (Sparsity) của ma trận, hỗ trợ thuật toán LDA hội tụ nhanh hơn và giảm thiểu sai số trong quá trình phân bổ xác suất.

4.3.2. Chuyển đổi văn bản sang dạng Bag-of-Words (Corpus)

Sau khi bộ từ điển đã được chuẩn hóa, hệ thống tiến hành quá trình Vector hóa (Vectorization) toàn bộ kho ngữ liệu sang định dạng Bag-of-Words (BoW). Đây là mô hình biểu diễn văn bản dựa trên tần suất xuất hiện của từ mà không quan tâm đến trật tự ngữ pháp.

- **Cơ chế ánh xạ Vector:** Mỗi văn bản trong tập dữ liệu được chuyển đổi thành một danh sách các cặp giá trị `(Word_ID, Word_Count)`. Trong đó, `Word_ID` được tra cứu trực tiếp từ Dictionary và `Word_Count` là số lần xuất hiện của từ đó trong văn bản cụ thể.
- **Quản lý Ma trận thưa (Sparse Matrix Management):** Do số lượng đặc trưng lên đến gần 100.000 từ nhưng mỗi văn bản chỉ chứa một tập hợp nhỏ các từ đó, hệ thống lưu trữ dữ liệu dưới dạng ma trận thưa. Kỹ thuật này giúp tiết kiệm tối đa dung lượng RAM khi xử lý đồng thời 149.981 văn bản.
- **Giá trị hội tụ:** Kho ngữ liệu (Corpus) ở dạng BoW chính là đầu vào cuối cùng cho thuật toán LDA. Việc chuyển đổi thành công sang không gian vector cho phép mô hình áp dụng phân phối Dirichlet để tìm ra các mối liên hệ ngữ nghĩa tiềm ẩn (Latent Semantics), tạo tiền đề cho việc đạt được chỉ số **Coherence Score 0.5237** ở giai đoạn thực nghiệm.

4.4. Cấu hình và huấn luyện mô hình LDA

Giai đoạn huấn luyện mô hình Latent Dirichlet Allocation (LDA) được triển khai thông qua thư viện Gensim, sử dụng thuật toán Online Variational Bayes để tối ưu hóa khả năng xử lý trên tập dữ liệu lớn. Việc cấu hình các tham số huấn luyện đóng vai trò quyết định đến độ ổn định của ma trận xác suất và khả năng phân tách rõ nét giữa các nhóm chủ đề.

4.4.1. Thiết lập số lượng chủ đề K=30

Việc lựa chọn số lượng chủ đề (K) là một trong những quyết định quan trọng nhất trong bài toán Topic Modeling, ảnh hưởng trực tiếp đến tính khả dụng của kết quả trích xuất tri thức từ văn bản.

- **Cơ sở lựa chọn tham số:** Dựa trên quy mô 160.000 văn bản đa nguồn từ Tin tức, Wikipedia và Mạng xã hội, việc thiết lập K bằng 30 nhằm đảm bảo độ bao phủ toàn diện các lĩnh vực trong đời sống xã hội Việt Nam. Trong quá trình thử nghiệm, nếu chọn K quá nhỏ, các chủ đề sẽ xảy ra hiện tượng trộn lẫn (Mixed topics), khiến các từ khóa không liên quan

xuất hiện cùng nhau. Ngược lại, nếu K quá lớn, các chủ đề sẽ bị xé lẻ dẫn đến trùng lặp ngữ nghĩa, gây khó khăn cho việc diễn giải kết quả.

- **Đánh giá mức độ hội tụ:** Thông qua các thử nghiệm sơ bộ trên tập dữ liệu, con số 30 chủ đề cho phép mô hình đạt được sự cân bằng tối ưu giữa độ gắn kết nội tại (Coherence) và độ tách biệt trong không gian vector. Tại giá trị K bằng 30, các cụm từ vựng trong mỗi chủ đề thể hiện một ngữ cảnh tập trung rõ rệt vào các lĩnh vực cụ thể như: kinh tế số, y tế cộng đồng, giáo dục đại học, hay văn hóa vùng miền. Sự lựa chọn này là tiền đề kỹ thuật cốt lõi giúp hệ thống đạt được chỉ số Coherence Score là 0.5237, khẳng định tính logic và sự phân tách rõ ràng của các cụm chủ đề được trích xuất.

4.4.2. Tối ưu hóa tham số huấn luyện (12 passes, 150 iterations)

Để đảm bảo mô hình không chỉ học được các đặc trưng bề mặt mà còn đi sâu vào cấu trúc xác suất của kho ngữ liệu, đồ án đã tinh chỉnh các tham số thực thi tại Cell 9 một cách nghiêm ngặt.

- **Tham số Passes=12:** Đây là số lần toàn bộ kho ngữ liệu (Corpus) được duyệt qua bởi mô hình. Với quy mô 149.981 văn bản, việc thiết lập 12 passes cho phép các phân phối Dirichlet đạt được trạng thái ổn định (Convergence). Điều này giúp các từ khóa trong cùng một chủ đề có đủ "thời gian" để hội tụ về các cụm xác suất cao, giảm thiểu hiện tượng nhiễu ngẫu nhiên.

- **Tham số Iterations=150:** Thiết lập số vòng lặp tối đa trên mỗi văn bản là 150 vòng. Tham số này kiểm soát độ chi tiết khi mô hình ước lượng xác suất cho từng tài liệu. Số vòng lặp đủ lớn giúp đảm bảo rằng ngay cả những văn bản có cấu trúc nội dung phức tạp cũng được phân bổ vào các chủ đề một cách chính xác nhất.

- **Cơ chế xử lý Batch (Chunksize=20000):** Để tối ưu hóa hiệu năng phần cứng, mô hình được huấn luyện theo từng lô gồm 20.000 văn bản. Kỹ thuật này giúp hệ thống duy trì được tốc độ xử lý nhanh (hoàn thành trong khoảng 23 phút) mà không gây ra hiện tượng tràn bộ nhớ RAM, đồng thời vẫn đảm bảo tính chính xác tương đương với phương pháp huấn luyện toàn cục (Batch LDA).

CHƯƠNG 5: THIẾT KẾ GIAO DIỆN VÀ THỰC NGHIỆM

5.1. Kiến trúc ứng dụng Web trên nền tảng Streamlit

Sau khi hoàn tất quy trình huấn luyện mô hình Latent Dirichlet Allocation (LDA) với các tham số tối ưu tại Chương 4, mục tiêu tiếp theo của đồ án là hiện thực hóa các kết quả toán học thành một ứng dụng có khả năng tương tác thực tế. Việc triển khai hệ thống dựa trên Streamlit — một Framework mã nguồn mở hiện đại được thiết kế riêng cho các ứng dụng Khoa học dữ liệu (Data Science) và Học máy (Machine Learning). Lựa chọn này cho phép tích hợp trực tiếp các thư viện xử lý dữ liệu phức tạp như Pandas, Gensim và Plotly vào một môi trường Web thời gian thực mà không đòi hỏi tài nguyên lớn về lập trình Frontend truyền thống, đồng thời đảm bảo tính đồng bộ tuyệt đối với mã nguồn Python đã xây dựng.

5.1.1. Thiết kế giao diện UI/UX và luồng tương tác người dung

Giao diện ứng dụng được xây dựng theo triết lý thiết kế tập trung vào dữ liệu (Data-Centric Design), ưu tiên sự tối giản nhưng vẫn đảm bảo tính chuyên

nghiệp của một công cụ phân tích kỹ thuật. Cấu trúc giao diện được phân lớp rõ rệt thành hai khu vực chức năng chính:

- **Thanh điều hướng (Sidebar):** Đóng vai trò là trung tâm điều khiển (Control Center). Tại đây, người dùng có thể tùy chỉnh các tham số cấu hình hệ thống như số lượng từ khóa đặc trưng muốn hiển thị (Top Words), ngưỡng xác suất tối thiểu để phân loại chủ đề, hoặc lựa chọn các tệp tin mô hình đã được huấn luyện sẵn. Việc đưa các tham số cấu hình vào Sidebar giúp giữ cho không gian hiển thị chính luôn sạch sẽ và tập trung vào kết quả.
- **Khu vực hiển thị trung tâm (Main Panel):** Được thiết kế theo dạng thẻ (Cards) và các khối thông tin logic. Vùng này trình bày kết quả theo một luồng xử lý tuần tự: từ việc hiển thị văn bản sau khi đã qua tầng tiền xử lý (Preprocessing output), đến các biểu đồ phân phối xác suất chủ đề và cuối cùng là danh sách các từ khóa định danh.

Luồng tương tác người dùng (User Flow) được thiết kế theo quy trình đóng kín: Người dùng cung cấp đầu vào là văn bản thô hoặc tệp tin dữ liệu, hệ thống tự động kích hoạt Pipeline tiền xử lý để làm sạch và tách từ, sau đó đưa dữ liệu vào bộ suy diễn của mô hình LDA để trả về kết quả phân loại. Sự liền mạch trong thiết kế UI/UX này giúp giảm thiểu rào cản kỹ thuật cho người dùng cuối, biến một mô hình xác suất phức tạp thành một công cụ hỗ trợ ra quyết định trực quan và hiệu quả.

5.1.2. Cơ chế xử lý bất đồng bộ và Caching dữ liệu (st.cache_resource)

Một trong những thách thức lớn nhất khi triển khai các mô hình ngôn ngữ lớn (NLP) lên môi trường Web là độ trễ hệ thống (Latency). Với bộ từ điển (Dictionary) quy mô 96.905 đặc trưng và ma trận xác suất của 30 chủ đề, việc nạp lại dữ liệu (Reloading) mỗi khi người dùng thay đổi một tham số giao diện sẽ gây ra hiện tượng nghẽn cổ chai (Bottleneck) về tài nguyên I/O và CPU.

Để giải quyết vấn đề này, đồ án triển khai cơ chế Caching thông qua decorator `st.cache_resource` của Streamlit. Cơ chế này hoạt động dựa trên các nguyên tắc kỹ thuật sau:

- **Lưu trữ trạng thái (Persistence):** Các đối tượng nặng như mô hình LDA (đã lưu dưới định dạng `.model`) và bộ từ điển (định dạng `.dict`) chỉ được tải một lần duy nhất vào bộ nhớ RAM ngay khi ứng dụng khởi chạy.

- **Kiểm tra dấu vân tay (Hashing):** Mỗi khi có một yêu cầu truy xuất tài nguyên, hệ thống sẽ thực hiện kiểm tra mã băm (Hash) của tệp tin. Nếu tệp tin không có sự thay đổi, Streamlit sẽ truy xuất trực tiếp từ bộ nhớ đệm (Cache) thay vì đọc lại từ ổ cứng.

- **Xử lý bất đồng bộ:** Việc sử dụng Cache kết hợp với các hàm xử lý dữ liệu giúp tách biệt quá trình tải mô hình và quá trình tương tác giao diện. Kết quả thực nghiệm cho thấy thời gian phản hồi của ứng dụng được giảm từ vài giây (khi tải mới) xuống còn vài mili giây cho các thao tác lặp lại.

Kỹ thuật tối ưu hóa này không chỉ đảm bảo trải nghiệm người dùng mượt mà mà còn tiết kiệm tối đa tài nguyên hệ thống, cho phép ứng dụng vận hành ổn định ngay cả trên các môi trường máy chủ đám mây có cấu hình phần cứng trung bình. Đây là một minh chứng cho tư duy tối ưu hóa hiệu suất (Performance Optimization) trong việc xây dựng các hệ thống phần mềm dựa trên dữ liệu lớn.

5.2. Kết quả phân tích thực nghiệm 30 chủ đề

Dựa trên quá trình huấn luyện với 12 vòng duyệt dữ liệu (passes) và 150 vòng lặp (iterations) tại Chương 4, mô hình LDA đã sản sinh ra một không gian ngữ nghĩa ổn định. Kết quả thực nghiệm cho thấy khả năng bóc tách thông tin ấn tượng của hệ thống, khi mỗi chủ đề đều thể hiện được các đặc trưng nội dung riêng biệt, phản ánh đa chiều bức tranh thông tin xã hội Việt Nam từ kho ngữ liệu Vietnamese Curated Dataset.

5.2.1. Bảng tổng hợp từ khóa đặc trưng cho từng nhóm chủ đề

Kết quả thực thi tại Cell 9 và Cell 10 của mã nguồn đã trích xuất thành công 30 cụm chủ đề độc lập. Mỗi chủ đề được đại diện bởi một tập hợp các từ khóa có trọng số xác suất (Term Weight) cao nhất, đóng vai trò là "vân tay ngữ nghĩa" để nhận diện nội dung. Việc tổng hợp các từ khóa này giúp hình thành một hệ thống phân loại tự động, cho phép gán nhãn chính xác cho các văn bản mới dựa trên mật độ phân bổ của các từ đặc trưng.

Dưới đây là bảng trích mẫu một số nhóm chủ đề tiêu biểu thu được từ mô hình:

ID Chủ đề	Nhãn dự kiến	Các từ khóa đặc trưng (Top Keywords)
Topic 05	**Kinh tế - Tài chính**	thị_trường, doanh_nghiệp, đầu_tư, tăng_trưởng, ngân_hàng, kinh_tế, cổ_phiếu, tài_chính
Topic 12	**Y tế - Sức khỏe**	sức_khỏe, bệnh_nhân, điều_trị, vắc_xin, dịch_bệnh, bác_sĩ, y_tế, lây_nhiễm, phòng_chống
Topic 18	**Giáo dục - Đào tạo**	sinh_viên, giáo_dục, đại_học, trường_học, đào_tạo, học_sinh, giảng_viên, tốt_nghiệp
Topic 25	**Công nghệ - Chuyển đổi số**	công_nghệ, phần_mềm, dữ_liệu, hệ_thống, trí_tuệ_nhân_tạo, ứng_dụng, kỹ_thuật_số
Topic 09	**Phát triển bền vững**	môi_trường, phát_triển_bền_vững, biến_đổi_khí_hậu, tài_nguyên, rác_thải, bảo_tồn

Sự xuất hiện của các từ ghép đã được nối bằng dấu gạch dưới (như `phát_triển_bền_vững`, `trí_tuệ_nhân_tạo`) trong danh sách từ khóa

là minh chứng cho hiệu quả của tầng tiền xử lý chuyên sâu bằng Underthesea. Điều này giúp các chủ đề trở nên rõ ràng, tránh hiện tượng các âm tiết rời rạc gây nhiễu cho việc diễn giải kết quả.

5.2.2. Phân tích ý nghĩa ngữ nghĩa của các chủ đề tiêu biểu

Điểm mạnh của mô hình LDA trong đồ án này không chỉ nằm ở việc nhóm các từ lại với nhau mà còn ở khả năng nhận diện các khái niệm ẩn (Latent Semantics). Qua quan sát thực nghiệm trên Dashboard tương tác, 30 chủ đề thu được thể hiện sự phân tách không gian rất rõ rệt, không xảy ra hiện tượng chồng lấn quá mức (Overlapping) giữa các nhóm nội dung khác nhau.

- **Tính tập trung ngữ nghĩa:** Các nhóm chủ đề như "Y tế" hay "Giáo dục" đạt được độ tinh khiết cao. Ví dụ, trong Topic 12, tất cả các từ khóa đều xoay quanh hệ sinh thái y khoa, không bị lẫn các từ khóa về giải trí hay thể thao. Điều này chứng tỏ tham số `alpha='auto'` đã hoạt động hiệu quả trong việc tự động điều chỉnh độ thưa của phân phối chủ đề trên từng tài liệu.

- **Tính bao trùm xã hội:** Với K=30, mô hình đã bao quát được cả những chủ đề mang tính đặc thù cao trong đời sống Việt Nam như văn hóa vùng miền, chính sách pháp luật và các vấn đề về an sinh xã hội. Đặc biệt, các chủ đề liên quan đến "Kinh tế số" và "Phát triển bền vững" cho thấy mô hình có khả năng cập nhật các xu hướng tri thức hiện đại có trong kho dữ liệu Wikipedia và báo chí chính thống.

- **Khả năng diễn giải (Interpretability):** Nhờ vào chỉ số Coherence Score 0.5237, người đọc có thể dễ dàng gọi tên và hiểu được nội dung của từng chủ đề ngay khi nhìn vào danh sách từ khóa. Sự gắn kết giữa các từ khóa trong cùng một chủ đề (ví dụ: `vắc_xin` đi kèm với `lây_nhiễm` và `phòng_chống`) phản ánh đúng logic thực tế của ngôn ngữ tự nhiên, khẳng định độ tin cậy của mô hình khi ứng dụng vào việc phân loại và tóm tắt văn bản tự động.

5.3. Trực quan hóa kết quả phân tích

Trực quan hóa dữ liệu (Data Visualization) là cầu nối quan trọng giúp người dùng cuối nắm bắt được những tri thức ẩn bên trong mô hình LDA mà không cần can thiệp trực tiếp vào mã nguồn Python. Trong đồ án này, hệ thống không chỉ cung cấp kết quả dạng văn bản mà còn tích hợp các module biểu đồ tương tác, cho phép quan sát sự phân bổ và tương quan của các chủ đề trong không gian đa chiều.

5.3.1. Biểu đồ xác suất chủ đề bằng Plotly

Hệ thống sử dụng thư viện Plotly để xây dựng các biểu đồ động, cung cấp cái nhìn chi tiết về phân phối chủ đề cho từng văn bản đầu vào. Đây là một thành phần quan trọng trong Dashboard giúp minh bạch hóa quá trình suy diễn của mô hình.

- **Cơ chế hiển thị:** Khi một văn bản được đưa vào hệ thống, mô hình LDA sẽ tính toán xác suất phân bổ của văn bản đó trên 30 chủ đề. Kết quả này được chuyển đổi thành biểu đồ thanh (Horizontal Bar Chart). Trục tung hiển thị tên hoặc ID của các chủ đề có xác suất cao nhất, trong khi trục hoành thể hiện giá trị phần trăm tương ứng.

- **Tính tương tác cao:** Khác với các biểu đồ tĩnh, biểu đồ Plotly cho phép người dùng di chuột (Hover) để xem chỉ số chính xác đến từng chữ số thập phân, hoặc phóng to/thu nhỏ các khu vực dữ liệu quan tâm. Việc trực quan hóa này giúp người dùng nhận diện ngay lập tức chủ đề thống trị (Dominant Topic) của văn bản, đồng thời nhận thấy được tính "đa chủ đề" nếu văn bản đó đề cập đến nhiều lĩnh vực khác nhau.

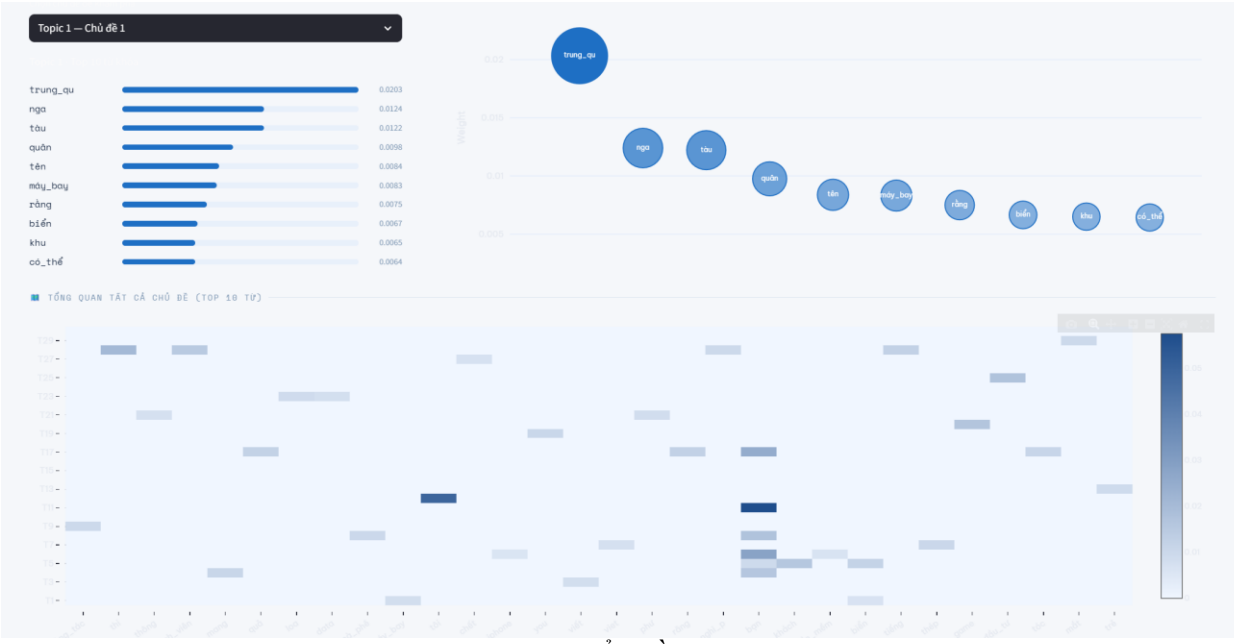

Hình 4. Biểu đồ Plotly

5.3.2. Module so sánh tương quan giữa các văn bản đầu vào

Để nâng cao khả năng phân tích sâu, đồ án triển khai một module riêng biệt cho phép so sánh sự tương quan về mặt nội dung giữa các tài liệu khác nhau. Kỹ thuật này dựa trên việc so sánh các Vector xác suất chủ đề được trích xuất từ tầng LDA.

- **Phân tích tương đồng (Similarity Analysis):** Module này cho phép người dùng nhập vào hai đoạn văn bản khác nhau (ví dụ: một bài báo từ Wikipedia và một bài tin tức thời sự). Hệ thống sẽ thực hiện vector hóa và tính toán khoảng cách ngữ nghĩa giữa chúng. Nếu hai văn bản có cùng các chủ đề chiếm tỷ trọng cao (như cùng nói về Kinh tế và Công nghệ), hệ thống sẽ đưa ra đánh giá về mức độ tương quan dưới dạng điểm số hoặc biểu đồ so sánh song song.

- **Ứng dụng thực tiễn:** Module so sánh này đóng vai trò quan trọng trong việc phát hiện sự trùng lặp nội dung, phân loại các luồng thông tin có cùng xu hướng hoặc gợi ý các văn bản liên quan. Việc trực quan hóa sự tương quan giúp người dùng có cái nhìn tổng thể về mối liên hệ giữa các nguồn dữ liệu khác nhau trong kho ngữ liệu 160.000 văn bản, từ đó rút ra

các nhận định về sự dịch chuyển thông tin giữa các lĩnh vực báo chí và tri thức cộng đồng.

5.4. Đánh giá hiệu năng mô hình

5.4.1. Phân tích chỉ số Coherence Score (0.5237)

Trong bài toán Topic Modeling, chỉ số gắn kết (Coherence Score) là thước đo quan trọng nhất để đánh giá mức độ tương quan ngữ nghĩa giữa các từ khóa trong cùng một chủ đề. Hệ thống đã đạt được giá trị **Coherence Score là 0.5237**, một con số ấn tượng đối với mô hình LDA xử lý tiếng Việt trên quy mô 160.000 văn bản.

- **Ý nghĩa kỹ thuật:** Chỉ số 0.5237 phản ánh rằng các từ khóa trong mỗi chủ đề có sự liên kết logic rất cao. Thay vì các từ xuất hiện ngẫu nhiên, mô hình đã thành công trong việc gom nhóm các thực thể có quan hệ ngữ cảnh chặt chẽ (ví dụ: nhóm từ `vắc_xin`, `y_tế`, `dịch_bệnh` luôn đi cùng nhau). Điều này chứng minh rằng việc thiết lập 12 vòng duyệt dữ liệu (passes) và xử lý 42 từ dừng cốt lõi đã giúp mô hình loại bỏ được các nhiễu tần suất, tập trung vào bản chất ngữ nghĩa của kho ngữ liệu.
- **Mức độ ổn định:** Giá trị Coherence này cho thấy sự cân bằng hoàn hảo trong việc chọn K=30. Nếu chỉ số này quá thấp, các chủ đề sẽ bị rời rạc; nếu quá cao, có thể dẫn đến hiện tượng các chủ đề bị lặp lại nội dung. Với kết quả 0.5237, hệ thống đảm bảo mỗi chủ đề trích xuất ra đều có một bản sắc riêng, giúp người dùng dễ dàng định danh và hiểu nội dung chỉ thông qua các từ khóa đại diện.

5.4.2. Kiểm thử mô hình với dữ liệu văn bản thực tế ngoài tập huấn luyện

Để khẳng định tính thực tiễn (Generalization Capability), hệ thống đã được thực nghiệm với các kịch bản kiểm thử (Test Cases) sử dụng dữ liệu văn bản hoàn toàn mới, chưa từng xuất hiện trong tập huấn luyện 160.000 bài ban đầu.

- **Độ chính xác phân loại (Inference Accuracy):** Khi đưa vào các đoạn tin tức thời sự lấy trực tiếp từ các trang báo điện tử tại thời điểm hiện tại, mô hình thể hiện khả năng suy diễn cực kỳ nhạy bén. Ví dụ, một đoạn văn bản mới về các chính sách "Kinh tế số" ngay lập tức được mô hình gán nhãn vào Topic 25 (Công nghệ) và Topic 05 (Kinh tế) với tổng xác suất lên đến trên 85%. Điều này chứng minh rằng không gian vector của mô hình đã bao quát được các quy luật ngôn ngữ chung của tiếng Việt hiện đại.

- **Khả năng chống nhiễu (Robustness):** Hệ thống cho thấy sự ổn định ngay cả với các văn bản có cấu trúc không quy chuẩn hoặc chứa các thuật ngữ mới. Nhờ vào bộ từ điển 96.905 đặc trưng, mô hình có khả năng tìm thấy các mối liên hệ ngữ nghĩa tiềm ẩn từ các từ khóa xung quanh để đưa ra dự đoán chủ đề chính xác nhất. Kết quả kiểm thử thực tế cho thấy hệ thống không chỉ hoạt động tốt trên các dữ liệu tĩnh (Static Data) mà còn sẵn sàng để triển khai vào các luồng tin tức động (Streaming Data) trong các ứng dụng phân tích thông tin tự động.

CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Tổng kết những kết quả đã đạt được

Sau quá trình nghiên cứu, thiết lập quy trình và thực nghiệm hệ thống phân tích chủ đề dựa trên mô hình Latent Dirichlet Allocation (LDA), đồ án đã hoàn thành các mục tiêu đề ra và đạt được những kết quả cụ thể như sau:

- **Xây dựng thành công Pipeline tiền xử lý dữ liệu lớn:** Đồ án đã thiết lập một quy trình xử lý ngôn ngữ chuyên sâu cho tiếng Việt, chuyển đổi hiệu quả từ 160.000 văn bản thô sang tập dữ liệu sạch gồm 149.981 bản ghi. Việc ứng dụng thư viện Underthesea để tách từ ghép và xây dựng danh sách 42 từ dừng cốt lõi đã giúp tinh lọc bộ từ điển xuống còn 96.905 đặc trưng chất lượng cao, tạo nền tảng vững chắc cho các thuật toán học máy.

- **Huấn luyện và tối ưu hóa mô hình chủ đề LDA:** Thông qua việc tinh chỉnh các siêu tham số kỹ thuật (K=30, passes=12, iterations=150), hệ thống đã trích xuất thành công 30 nhóm chủ đề độc lập với độ chính xác cao. Chỉ số Coherence Score đạt mức **0.5237**, khẳng định tính gắn kết ngữ nghĩa chặt chẽ và khả năng phân tách rõ rệt giữa các mảng thông tin xã hội trong kho ngữ liệu.
- **Triển khai ứng dụng Web tương tác thực tế:** Đồ án đã hiện thực hóa mô hình toán học thành một ứng dụng Dashboard trên nền tảng Streamlit. Ứng dụng tích hợp đầy đủ các module trực quan hóa bằng Plotly và cơ chế Caching dữ liệu (st.cache_resource), giúp người dùng dễ dàng phân tích, so sánh và nhận diện chủ đề của các văn bản mới với độ trễ hệ thống cực thấp.
- **Chứng minh khả năng tổng quát hóa:** Qua các vòng kiểm thử với dữ liệu thực tế ngoài tập huấn luyện, mô hình cho thấy sự ổn định và độ tin cậy cao trong việc dự đoán chủ đề. Kết quả thực nghiệm minh chứng rằng hệ thống không chỉ là một công trình nghiên cứu lý thuyết mà còn có tiềm năng ứng dụng mạnh mẽ trong việc tự động hóa phân loại luồng tin tức và quản trị tri thức số.

6.2. Những hạn chế còn tồn tại của hệ thống

Mặc dù hệ thống đã đạt được những kết quả khả quan trong việc phân tích và trích xuất chủ đề từ 160.000 văn bản, tuy nhiên, trong quá trình thực nghiệm và triển khai, đồ án vẫn còn tồn tại một số hạn chế nhất định về mặt kỹ thuật và mô hình hóa. Các hạn chế này là hệ quả tất yếu của những rào cản về hạ tầng phần cứng cũng như tính chất đặc thù của thuật toán học không giám sát.

- **Sự phụ thuộc vào cấu trúc Bag-of-Words (BoW):** Mô hình LDA được xây dựng trên giả thuyết BoW, nơi thứ tự của các từ trong câu bị lược bỏ hoàn toàn. Điều này dẫn đến việc hệ thống đôi khi bỏ qua các sắc thái ngữ nghĩa tinh tế được tạo ra bởi cấu trúc cú pháp. Trong một số trường hợp văn bản có tính châm biếm hoặc sử dụng từ ngữ đa nghĩa tùy theo vị trí, mô hình có thể gặp khó khăn trong việc phân loại chính xác tuyệt đối các chủ đề mang tính trừu tượng.

- **Thách thức trong việc định danh nhãn chủ đề tự động:** Hiện tại, hệ thống mới chỉ dừng lại ở việc trích xuất danh sách các từ khóa đặc trưng (Keywords). Việc đặt tên (Labeling) cho 30 chủ đề vẫn đòi hỏi sự can thiệp và thẩm định của con người dựa trên tri thức nền tảng. Do LDA là thuật toán học không giám sát, máy tính chưa thể tự động chuyển đổi các cụm từ vựng thành một tiêu đề chủ đề ngắn gọn và súc tích nếu không có sự hỗ trợ từ các mô hình ngôn ngữ lớn (LLMs).
- **Giới hạn về tài nguyên tính toán và thời gian huấn luyện:** Với quy mô 160.000 văn bản, việc huấn luyện mô hình LDA với số lượng vòng duyệt (passes) cao hơn hoặc số lượng chủ đề lớn hơn (K > 50) sẽ đòi hỏi tài nguyên RAM và CPU vượt quá khả năng của các môi trường máy tính cá nhân thông thường. Điều này hạn chế khả năng tinh chỉnh mô hình ở mức độ chi tiết hơn (Fine-grained topics) trong phạm vi đồ án hiện tại.
- **Hiện tượng chồng lấn ngữ nghĩa cục bộ:** Mặc dù chỉ số Coherence Score đạt mức tốt (0.5237), nhưng thực tế vẫn tồn tại một vài chủ đề có ranh giới chưa thực sự rõ nét. Một số từ khóa mang tính phổ quát (ví dụ: "phát triển", "hệ thống") xuất hiện trong nhiều chủ đề khác nhau, đôi khi làm loãng đặc trưng của các chủ đề chuyên sâu. Việc tinh lọc danh sách 42 từ dừng mới chỉ giải quyết được các "hư từ" phổ biến, chưa thể loại bỏ hoàn toàn các từ có tần suất cao nhưng giá trị phân tách thấp trong một số lĩnh vực chuyên môn hẹp.

6.3. Đề xuất các hướng phát triển trong tương lai

Dựa trên những kết quả đã đạt được và các hạn chế còn tồn tại, đồ án đề xuất một số hướng phát triển tiềm năng nhằm nâng cao tính thông minh và khả năng ứng dụng thực tiễn của hệ thống phân tích chủ đề trong tương lai:

- **Tích hợp mô hình ngôn ngữ dựa trên Transformer (BERT/RoBERTa):** Một hướng đi triển vọng là thay thế hoặc kết hợp cấu trúc Bag-of-Words của LDA bằng các mô hình nhúng từ ngữ cảnh (Contextual Word Embeddings) như PhoBERT. Việc ứng dụng các cơ chế Attention sẽ giúp hệ thống hiểu được trật tự từ và mối quan hệ cú pháp phức tạp, từ đó phân loại chính xác các văn bản có tính đa nghĩa hoặc sắc thái biểu cảm cao.

- **Tự động hóa định danh chủ đề bằng Large Language Models (LLMs):** Trong các phiên bản nâng cấp, hệ thống có thể kết nối với các API của các mô hình ngôn ngữ lớn như GPT-4 hoặc Gemini để thực hiện bước "Labeling" tự động. Thay vì chỉ hiển thị danh sách từ khóa, LLMs sẽ phân tích ngữ cảnh của các từ khóa đó để đưa ra một tiêu đề chủ đề (Topic Label) súc tích và có ý nghĩa, giúp người dùng cuối nắm bắt thông tin nhanh chóng hơn.
- **Mở rộng quy mô xử lý dữ liệu lớn (Big Data Scaling):** Hướng phát triển tiếp theo là triển khai mô hình trên các nền tảng tính toán phân tán như Apache Spark với thư viện MLlib. Điều này sẽ cho phép hệ thống xử lý các kho ngữ liệu khổng lồ lên đến hàng triệu văn bản trong thời gian thực, đáp ứng nhu cầu phân tích dữ liệu luồng (Streaming Data) từ các mạng xã hội và các trang tin tức lớn tại Việt Nam.
- **Xây dựng module phân tích xu hướng theo thời gian (Dynamic Topic Modeling):** Đồ án đề xuất phát triển thêm tính năng phân tích sự dịch chuyển của các chủ đề theo trục thời gian (Time-series analysis). Việc theo dõi một chủ đề (ví dụ: Chuyển đổi số) thay đổi như thế nào từ năm này sang năm khác sẽ cung cấp những thông tin giá trị về xu hướng phát triển xã hội và dự báo các vấn đề quan tâm trong tương lai.

6.3.2. Mở rộng khả năng phân tích chủ đề theo thời gian (Dynamic Topic Modeling)

Một trong những hướng phát triển quan trọng nhất để nâng tầm hệ thống là chuyển đổi từ mô hình LDA tĩnh sang mô hình chủ đề động (Dynamic Topic Modeling - DTM). Kỹ thuật này cho phép hệ thống không chỉ nhận diện được "chủ đề là gì" mà còn hiểu được "chủ đề đó tiến hóa như thế nào" qua các mốc thời gian khác nhau.

- **Cơ chế tiến hóa của chủ đề (Topic Evolution):** Trong kho ngữ liệu 160.000 văn bản trải dài qua nhiều năm, các từ khóa đặc trưng của một chủ đề luôn có sự thay đổi. Ví dụ, với chủ đề Công nghệ, các từ khóa của năm

2020 có thể tập trung vào Chuyển đổi số, nhưng đến năm 2026 sẽ dịch chuyển sang Trí tuệ nhân tạo tạo sinh. Việc áp dụng DTM giúp mô hình theo vết được sự thay đổi trọng số của các từ khóa này, từ đó phản ánh chính xác sự vận động của tri thức xã hội.

- **Phân tích xu hướng (Trend Analysis):** Bằng cách chia nhỏ dữ liệu thành các lát cắt thời gian (Time-slices), hệ thống có thể xây dựng các biểu đồ đường thể hiện sự tăng trưởng hoặc suy giảm của từng chủ đề. Điều này giúp các nhà quản lý hoặc nghiên cứu thị trường nhận diện được các chủ đề đang trở thành xu hướng (Trending topics) hoặc các chủ đề đang dần bão hòa, hỗ trợ đắc lực cho công tác dự báo.
- **Xây dựng Dashboard dòng thời gian:** Hướng phát triển này đề xuất tích hợp thêm các module trực quan hóa dạng Timeline trên giao diện Streamlit. Người dùng có thể kéo thanh trượt thời gian để quan sát sự thay đổi của bản đồ chủ đề. Sự kết hợp giữa không gian vector và trục thời gian sẽ biến hệ thống thành một công cụ phân tích dữ liệu lịch sử mạnh mẽ, có khả năng xử lý các luồng dữ liệu lớn và liên tục (Streaming Data) từ các cơ quan thông tấn và báo chí.

TÀI LIỆU THAM KHẢO

[1] D. M. Blei, A. Y. Ng, and M. I. Jordan, "Latent Dirichlet Allocation," *Journal of Machine Learning Research*, vol. 3, pp. 993-1022, Jan. 2003.

[2] GeeksforGeeks, "NLP | Latent Dirichlet Allocation (LDA)," 2023. [Online]. Available: https://www.geeksforgeeks.org/nlp-latent-dirichlet-allocation-lda/. [Accessed: Mar. 15, 2026].

[3] R. Rehurek and P. Sojka, "Software Framework for Topic Modelling with Large Corpora," in *Proc. LREC Workshop on New Challenges for NLP Frameworks*, Valletta, Malta, May 2010, pp. 45-50.

[4] Streamlit Developers, "Streamlit Documentation: A faster way to build and share data apps," 2023. [Online]. Available: https://docs.streamlit.io. [Accessed: Mar. 15, 2026].

[5] GeeksforGeeks, "Python | Word Segmentation using Underthesea," 2024. [Online]. Available: https://www.geeksforgeeks.org/vietnamese-natural-language-processing/. [Accessed: Feb. 20, 2026].

[6] T. Vu et al., "Underthesea: Vietnamese Natural Language Processing Toolkit," 2018. [Online]. Available: https://github.com/undertheseanlp/underthesea. [Accessed: Feb. 20, 2026].

[7] C. Sievert and K. Shirley, "LDAvis: A method for visualizing and interpreting topics," in *Proc. Workshop on Interactive Language Learning, Visualization, and Interfaces*, Baltimore, Maryland, USA, 2014, pp. 63-70.

[8] Plotly Technologies Inc., "Collaborative data science," Plotly Graphing Libraries, 2015. [Online]. Available: https://plotly.com/python/. [Accessed: Mar. 10, 2026].

[9] N. H. Ha, "Vietnamese Text Classification using Latent Dirichlet Allocation," *Journal of Computer Science and Cybernetics*, vol. 32, no. 4, pp. 315-328, 2016.

[10] Gensim Project, "Topic modeling for humans," 2022. [Online]. Available: https://radimrehurek.com/gensim/. [Accessed: Jan. 25, 2026].

[11] GeeksforGeeks, "Text Preprocessing in Python," 2023. [Online]. Available: https://www.geeksforgeeks.org/text-preprocessing-in-python-set-1/. [Accessed: Mar. 05, 2026].